제6회 K-인공지능 제조데이터 분석 경진대회 보고서

프로젝트명	CN7 및 RG3 사출성형 품질위험 예측과 검사 우선순위 지원
팀명	후추
내용요약	<CN7> CN7 사출성형 공정 데이터를 기반으로 제품별 품질위험을 생산 Cycle 완료 후 최종 품질검사 이전에 위험도를 산출하는 모델을 구축하였다. 공정 센서값과 시간 흐름에 따른 변화 정보를 함께 반영하여 불량 발생 가능성이 높은 제품을 선별하였다. 생산 위치와 공정 특성까지 고려함으로써 단순 센서값만 사용하는 방식보다 세부적인 위험도 판단이 가능하도록 설계하였다. 예측 결과를 활용해 모든 제품을 동일하게 검사하는 대신 품질위험이 높은 제품을 우선적으로 검사할 수 있도록 하였다. 또한 모델이 판단하기 어려운 제품까지 검사 대상으로 포함하여 미검출 위험을 줄이는 검사 우선순위 정책을 적용하였다. 주요 공정 영향요인을 분석하여 품질위험 발생에 영향을 주는 온도, 회전, 공정시간 등의 변화를 함께 확인할 수 있도록 하였다.이를 통해 CN7은 품질위험 조기예측과 검사 자원의 효율적 배분을 동시에 지원하는 현장 적용형 모델로 제안하였다. <RG3> RG3 사출성형 공정에서는 생산 시점과 세션별 공정 변화를 반영하여 제품의 품질위험을 예측하고자 하였다. 센서값과 최근 공정 기준의 차이를 나타내는 Absolute EWMA5로 위험순위를 산출하였다. 분석 결과 일부 온도 및 압력 관련 변수에서 품질위험과 연관된 공정 변화 패턴을 확인하였다. 다만 미래 생산 구간에서 센서 분포와 공정 조건이 크게 변화하면서 기존 예측모델의 위험도 판단 성능이 불안정해지는 현상이 확인되었다. 이에 RG3는 단순 예측점수만으로 검사 우선순위를 결정하기보다 공정 분포 변화와 이상 여부를 함께 확인하는 방식이 필요하다고 판단하였다. 현장 도입 시에는 Session별 공정분포를 별도로 모니터링하고 변화가 큰 경우 기존 품질검사를 유지하는 운영방안을 제안하였다. 이를 통해 RG3는 품질위험 순위화와 향후 공정변화 감시를 제안하는 보수적인 검사 우선순위 지원 전략을 제안하였다.

상기 본인(팀)은 위의 내용과 같이 제6회 K-인공지능 제조데이터 분석 경진대회 결과 보고서를 제출합니다.

2026년 10월 7일

팀장 : 박 소 희 (서명)
팀원 : 주 민 혁 (서명)
팀원 : 안 효 원 (서명)

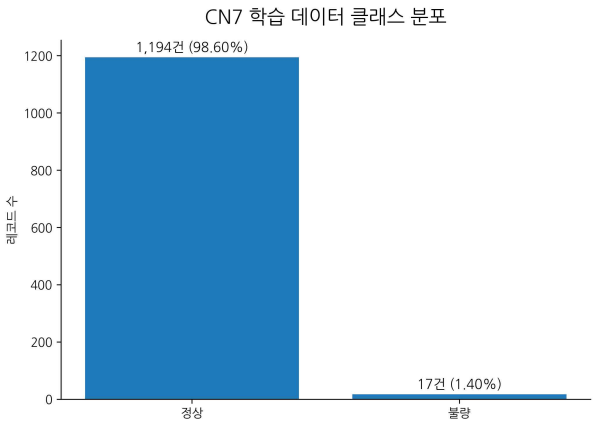
(사)중소기업기술혁신협회 귀중

□ 제1장. 데이터 이해 및 진단〔15점〕

○ 1. 분석 데이터 구성 - CN7

1) 기존 제공 데이터

	CN7
분석 대상	사출성형 공정
train 데이터	moldset_labeled_cn7
test 데이터	moldset_unlabeled_cn7
전체 레코드	1,211
정상	1,194
불량	17
불량 비율	약 1.40%
고유 생산 cycle	606
RH	606
LH	605
초기 공정 센서	24개
상수변수 제거 후 최종 공정 센서	23개



- CN7 데이터는 개별 제품 단위의 레코드지만, 동일한 TimeStamp를 가지는 LH/RH 제품은 하나의 생산 Cycle에서 생성되며 동일한 공정 센서 값을 공유하는 구조임을 확인함.
- 따라서 본 분석에서는 각 행을 서로 독립적인 데이터로 보는 것이 아니라 생산 Cycle과 제품 Side를 함께 고려하는 데이터 구조로 해석함

2) 원본 데이터 추가 활용

- 대회에 제공되지는 않았지만, KAMP에서 공개한 사출 성형 데이터의 원본 생산 데이터인 labeled_data.csv를 보조 원천 데이터로 활용함
- moldset_labeled_cn7.csv에는 모델링을 위해 Standard Scaling된 공정 센서값이 포함되어 있으나, 스케일링 이전의 원본 물리값과 생산순서를 확인할 수 있는 TimeStamp, PART_NAME 등의 생산 메타정보가 제한되어 있었음.
- 이에 labeled_data.csv를 활용하여 TimeStamp, PART_NAME, Side 정보와 원본 공정값을 복원함.
- 이에 따라 labeled_data.csv를 활용하여 다음과 같은 정보를 복원함

	원천	활용 목적
TimeStamp	labeled_data.csv	생산 순서 복원, Cycle 구성, 시간 기반 파생변수 생성
PART_NAME	labeled_data.csv	CN7 및 LH/RH 제품 구분

Side(RH/LH)	PART_NAME에서 파생	동일 공정조건에서 제품 Side 차이 반영
원본 공정값	labeled_data.csv	스케일링 전 실제 공정 상태 확인 및 EDA
이후 생산 구간	labeled_data.csv	미래 시점 Failure Episode 및 시간 일반화 검증

- side 정보를 복원한 이유는 동일한 TimeStamp의 LH와 RH가 동일 센서 값을 공유함에도 품질 결과는 Side별로 달라질 수 있기 때문임.
- 공정 센서만 사용하는 경우 이러한 차이를 모델이 구분할 수 없으므로 Side를 하나의 제품 구조 정보로 활용함

3) 생산 Cycle 및 Side 구조 분석
- 대부분의 Cycle은 LH와 RH 제품이 함께 존재했으며, 동일 TimeStamp 내부에서는 두 Side의 23개 공정 센서값이 동일했음
- CN7은 생산 Cycle -> 공정조건 -> LH/RH 제품 -> 개별 품질 결과와 같은 계층적 구조를 가짐
- 이는 모델링 과정에서 매우 중요한 데이터 구조임
- 동일 Cycle의 LH와 RH가 서로 다른 Train/Validation Fold에 배치될 경우 사실상 동일한 공정조건이 양쪽 데이터에 동시에 존재하게 되어 검증 성능이 과대평가 될 수 있기 때문임.

4) 공정의 시간적 연속성 분석
- CN7은 각각의 생산 Cycle이 완전히 독립적인 사건이라기보다 직전 생산 상태의 영향을 많이 받는 연속 공정임
- EDA 결과 직전 1개 Cycle과의 단순 변화량보다 최근 여러 Cycle동안 유지된 공정 수준이 불량과 더 높은 관련성을 보임
- 이는 최근 생산 과정에서 누적되어 형성된 공정 상태와 관계가 있을 가능성을 보여줌

5) 불량 발생의 시간적 집중도 분석
- CN7의 불량은 전체 기간에 균일하게 발생하지 않고 특정 시점에 집중되는 형태를 보임

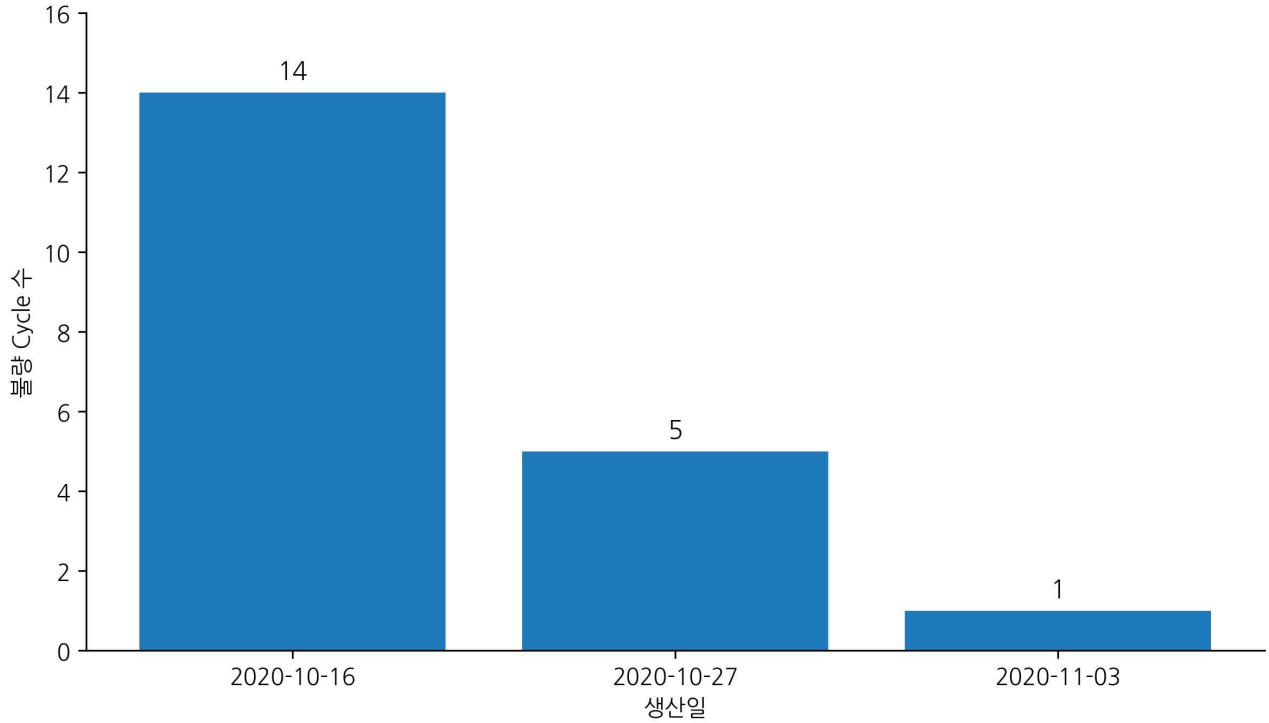
날짜	불량 Cycle 수	특징
2020-10-16	14	초기 불량이 연속적으로 집중

2020-10-27	5	이전 불량과 상당한 시간 간격 후 새로운 불량 군집 발생
2020-11-03	1	단일 불량 발생

* 10/27·11/03 데이터는 시간 일반화 및 Failure Regime 진단에 별도 활용

※ CN7 학습데이터의 불량은 부품 단위 17건이며, 아래 날짜·Failure Episode 분석은 labeled_data.csv에서 복원한 이후 생산구간을 포함한 Cycle 단위 진단이므로 집계 단위와 대상 기간이 다름.

날짜별 CN7 불량 Cycle 발생 수



- 특히 2020년 10월 16일에는 여러 불량 Cycle이 짧은 시간 간격으로 연속해서 발생함
- 반면 10월 27일의 불량은 초기 불량 이후 장시간이 지난 다음 새로운 형태로 나타남
- 따라서 전체 불량을 하나의 동일한 분포로 보기보다는, 시간적으로 연속되어 발생한 불량을 Failure Episode 단위로 구분하여 추가 분석함

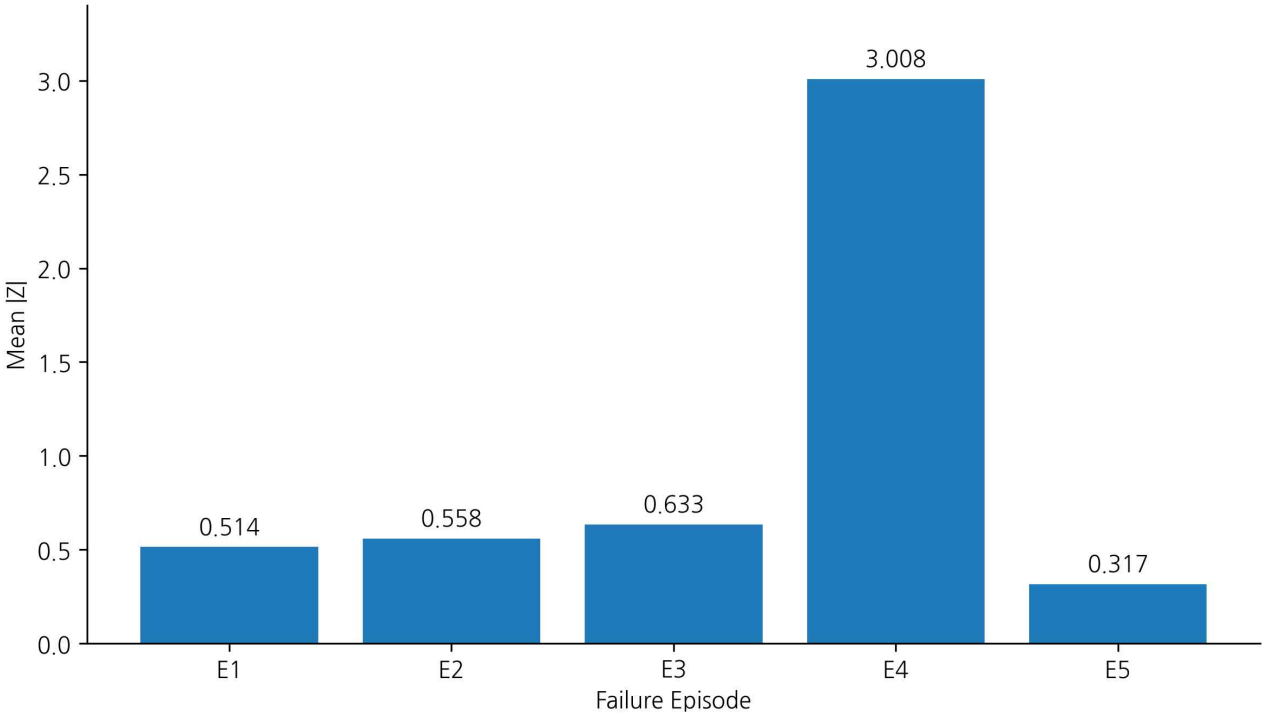
6) Failure Episode별 공정 패턴 비교

- Episode에 대해 정상 데이터의 평균과 표준편차를 기준으로 센서값을 표

준화하고, 정상 공정으로부터 얼마나 벗어났는지를 Z-score로 계산함

Episode	Mean |Z|	Max |Z|	|Z| > 2 변수 수	해석
E1	0.514	2.975	2	일부 금형온도 변화
E2	0.558	3.122	2	E1과 유사
E3	0.633	3.098	3	E1/E2와 유사한 초기 Failure regime
E4	**3.008**	**17.245**	**7**	기존과 전혀 다른 강한 공정 변화
E5	0.317	0.832	0	정상 분포와 상당히 유사

Failure Episode별 정상 공정 대비 평균 이탈 정도

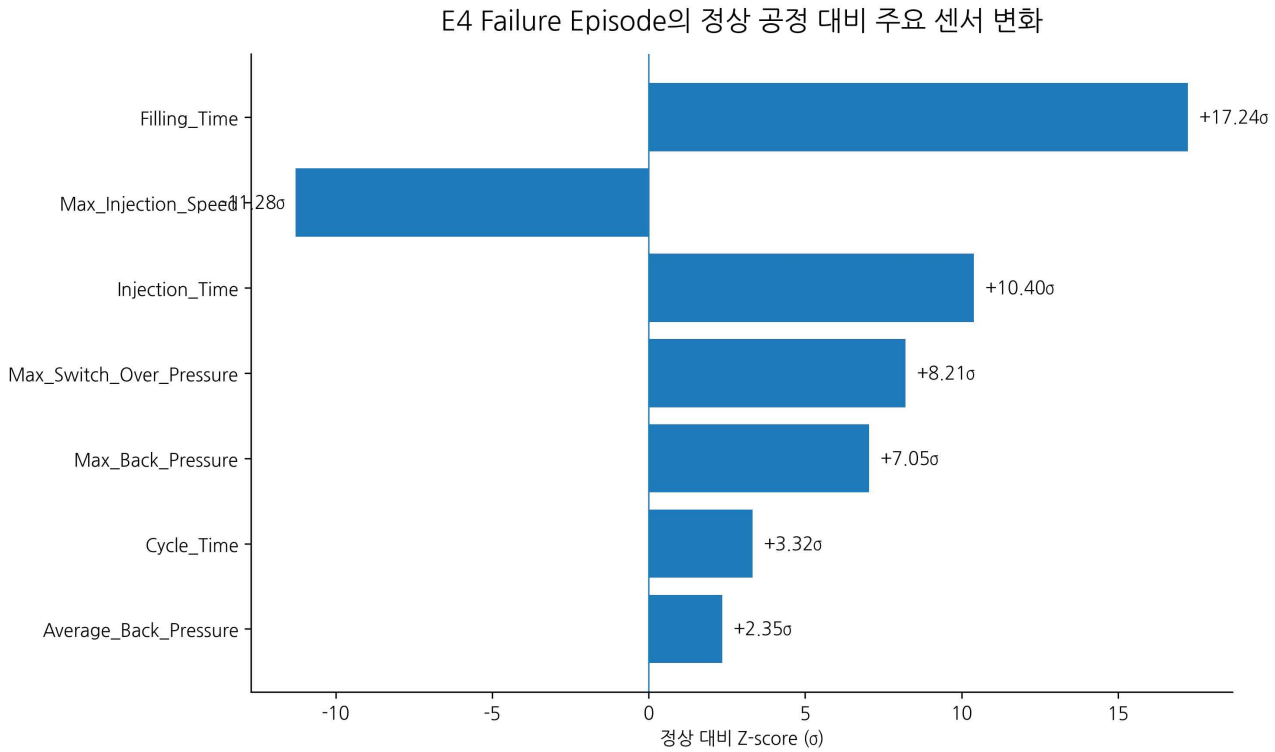


- E1~E3는 정상 공정에서 일부 차이를 보였지만 전체적인 공정 패턴은 비교적 유사함
- 실제 Episode 패턴 상관계수 역시 E1-E2가 0.9120, E2-E3가 0.7439로 높은 유사성을 나타냄
- 반면 10월 27일 발생한 E4는 이전 Episode와 매우 다른 공정 패턴을 보였다. 특히 E3와 E4의 정상 대비 센서 변화 패턴 상관계수는 -0.5566이었으며, Z-score 기반 Euclidean Distance 역시 28.243으로 크게 나타냄
- 동일한 CN7 불량이라 하더라도 불량이 발생하는 공정 패턴이 하나로 고정되어 있지 않을 가능성을 의미함

7) E4에서 확인된 주요 공정 변화

- E4는 정상 생산구간과 비교했을 때 여러 공정변수가 동시에 크게 변화함

변수	정상 대비 변화
Filling_Time	**+17.24 σ**
Max_Injection_Speed	**-11.28 σ**
Injection_Time	**+10.40 σ**
Max_Switch_Over_Pressure	**+8.21 σ**
Max_Back_Pressure	**+7.05 σ**
Cycle_Time	+3.32 σ
Average_Back_Pressure	+2.35 σ

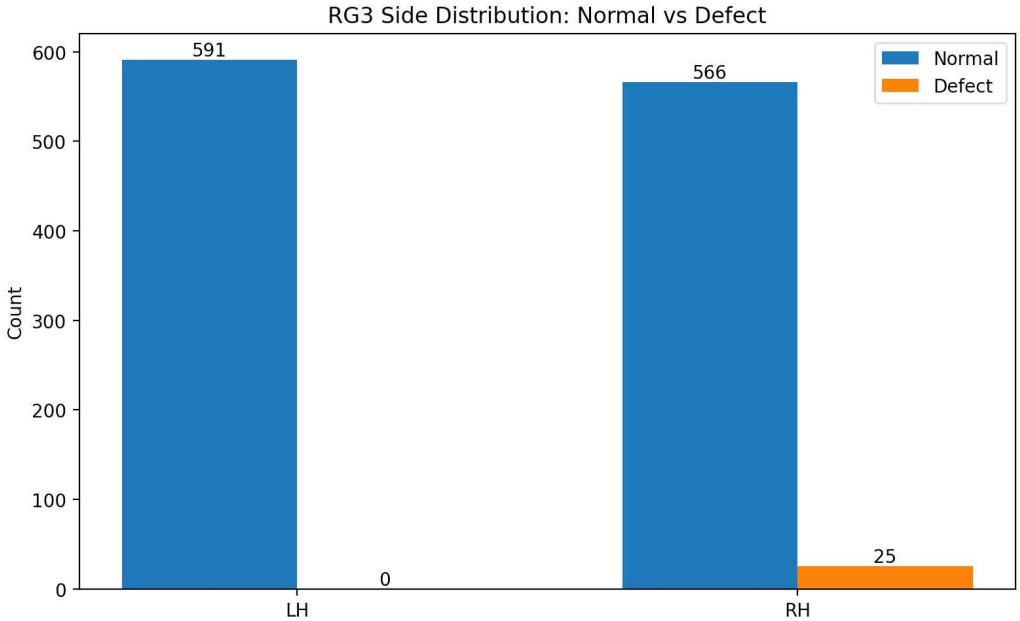


- 특히 충전시간과 사출시간은 크게 증가한 반면 최대 사출속도는 크게 감소하였고, Switch Over Pressure와 Back Pressure는 동시에 상승함
- 따라서 E4는 하나의 센서 이상이라기보다 사출·충전·압력 관련 공정 조건이 동시에 변화한 다변량 공정 이상 상태로 해석할 수 있음
- 단순히 개별 센서의 임계값만을 이용해 불량을 판단하는 것보다 여러 공정변수의 조합과 최근 생산상태를 함께 고려하는 다변량 모델이 필요함을 보여줌

○ 2. 분석 데이터 구성 - RG3

1) 기존 제공 데이터

항목	RG3
분석 대상	사출성형 공정
Train 데이터	moldset_labeled_rg3
전체 레코드	1,182
정상	1,157
불량	25
불량 비율	약 2.12%
RH	591
LH	591
초기 공정 센서	24개
상수변수 제거 후 공정 센서	23개



- RG3 전체 데이터는 1,182건으로 구성되며 정상 1,157건, 불량 25건으로 불량 비율은 약 **2.12%**임.
- 정상 데이터가 약 97.88%를 차지하는 심한 클래스 불균형 구조이므로 Accuracy만으로 모델 성능을 평가하는 것은 적절하지 않음.

- 전체 데이터는 RH 591건, LH 591건으로 동일하게 구성되어 있음.
- 전체 불량 25건의 Side 분포를 확인한 결과 25건 모두 RH에서 발생하였으며 LH에서는 불량이 한 건도 관찰되지 않음.
- 따라서 전체 RH/LH 데이터를 그대로 학습할 경우 모델이 실제 공정 상태보다 Side 정보를 이용하여 불량을 구분하는 Shortcut Learning이 발생할 가능성이 있음.
- 이에 최종 불량위험 모델은 RH 591건을 중심으로 구축하고, LH는 불량 학습사례가 존재하지 않으므로 AI 자동판정 대상에서 제외하는 방향으로 분석범위를 설정함.

2) 원본 생산정보 추가 활용

- 기존 moldset_labeled_rg3에 labeled_data.csv를 매칭하여 TimeStamp, PART_NAME, RH_LH 등 생산정보를 복원함.
- 분석용 데이터에는 다음과 같은 생산 맥락정보를 포함함.

정보	분석 활용
TimeStamp	생산순서 복원, 날짜별 분석, 생산 Session 구분
PART_NAME	RG3 RH/LH 제품 위치 확인
RH_LH	RH/LH 데이터 구분
original_index	원본 데이터 행 추적
공정 센서값	불량 공정상태 및 시간 변화 분석

- PART_NAME과 RH_LH의 관계를 확인한 결과 두 변수는 일대일로 대응함.

  * RG3 MOLD'G W/SHLD, LH→ LH
  * RG3 MOLD'G W/SHLD, RH→ RH

- 따라서 RH 데이터만을 모델링할 경우 PART_NAME과 RH_LH는 모두 하나의 값만 가지게 되므로 모델 Feature에서는 제외하고 데이터 식별용으로만 유지함.
- original_index역시 공정상태를 나타내는 변수가 아니므로 모델 학습에는 사용하지 않음.

3) RH/LH 불량 발생구조 분석

Side	정상	불량	전체	불량률
LH	591	0	591	0.00%
RH	566	**25**	591	**4.23%**
전체	1,157	25	1,182	2.12%

- RG3에서 관찰된 25개 불량은 모두 RH에 위치함.
- 이는 현재 제공 데이터만으로는 LH의 불량 발생조건을 지도학습할 수 없다는 의미임.
- 또한 RH/LH 전체를 하나의 모델에 입력할 경우 RH_LH 자체가 불량 여부를 지나치게 쉽게 구분하는 정보가 될 수 있음.
- 따라서 RG3에서는 Side 자체를 불량예측 Feature로 사용하는 대신 RH만 분리하여 공정센서 기반의 위험도 모델을 구축함.
- LH 제품은 AI가 정상으로 판정하는 것이 아니라 “불량 학습사례 부족으로 자동 판정을 보류하고 기존 품질검사를 유지하는 대상”으로 구분함.

4) 공정 데이터 품질 및 Scaling 구조 분석

- RH 591건을 기준으로 기본적인 데이터 품질을 점검한 결과 다음과 같음.

점검 항목	결과
결측치	없음
무한대 값	없음
완전 중복	없음
동일 공정조건 중복	없음
상수 공정변수	Clamp_Open_Position
Scaling	Standard Scaling 적용 확인
최종 기본 공정변수	23개

- RH 데이터에서는 결측치와 무한대 값이 발견되지 않아 별도의 결측치 대체를 수행하지 않음.
- 모든 컬럼이 완전히 동일한 중복행 또한 존재하지 않음.
- TimeStamp, Target 및 식별정보를 제외한 24개 공정 센서값만 비교

한 결과에도 완전히 동일한 공정조건 중복은 확인되지 않음.

- Clamp_Open_Position은 RH 전체 데이터에서 하나의 값만 가지는 상수변수로 확인되어 모델 Feature에서 제거함.
- 상수변수 제거 후 최종적으로 23개 기본 공정변수를 사용함.

5) Standard Scaling 구조 확인

- 상수변수를 제외한 공정변수들의 평균과 표준편차를 확인한 결과 모든 변수의 평균은 거의 0, 표준편차는 약 1.0008로 나타남.
- 따라서 RG3 데이터에는 이미 Standard Scaling이 적용된 상태임을 확인함.
- 즉 현재 센서값은 원래 물리단위를 직접 의미하기보다 각 변수의 기준 분포에서 상대적으로 어느 위치에 있는지를 나타내는 값임.
- 따라서 다음 원칙을 적용함.
- 추가 Standard Scaling을 수행하지 않음.
- 단순 분산을 이용한 저분산 Feature 제거를 수행하지 않음.
- 표준화된 값 자체를 실제 물리적 공정 Set-point로 해석하지 않음.
- 변수의 정상/불량 차이, 시간변화, 생산 Session 변화 및 모델 성능을 종합하여 사용 여부를 판단함.

6) 공정변수의 고유값 구조 분석

- 일부 공정변수는 실수형이지만 실제 고유값의 수가 매우 적은 형태를 보임.

변수	고유값 수
Filling_Time	**2**
Injection_Time	**3**
Clamp_Close_Time	**3**
Max_Screw_RPM	**4**
Average_Screw_RPM	**4**
Cushion_Position	7
Max_Injection_Speed	7
Plasticizing_Position	8

- 이러한 변수들은 완전한 연속형 센서라기보다 몇 가지 공정 설정상태 또는 Process Regime을 나타낼 가능성이 있음.
- 다만 고유값이 적다는 이유만으로 변수를 제거하지 않고 정상/불량 분포 및 생산 Session과의 관계를 추가 확인함.
- 특히 이후 분석에서 일부 변수의 차이가 불량 자체보다 생산 Session의 공정 운전조건 차이를 설명할 가능성이 확인되어, 절대 센서값에만 의존하는 모델의 한계를 추가 점검함.

7) 불량 발생의 시간적 분포 분석

- RH 데이터의 생산기간은 다음과 같음.
  * 시작: 2020-10-21 00:16:26
  * 종료: 2020-10-23 07:46:03
- 날짜별 정상・불량 분포는 다음과 같음.

날짜	정상	불량
2020-10-21	41	**0**
2020-10-22	285	**15**
2020-10-23	240	**10**

- 전체 불량 25건은 모두 10월 22일 이후에 발생함.
- 즉 RG3 불량은 전체 생산기간에 균일하게 분포하지 않고 생산시점 및 공정상태 변화와 함께 나타나는 구조를 보임.
- 실제 불량 발생시각을 확인한 결과 다음과 같은 시간구간에서 반복적으로 불량이 관찰됨.
  * 10월 22일 00:51 ~ 01:57
  * 10월 22일 04:46 ~ 07:37
  * 10월 23일 01:03 ~ 02:25
  * 10월 23일 05:15 ~ 05:59
  * 10월 23일 07:15 ~ 07:21

- 일부 불량은 2~7분 정도의 짧은 간격으로 연속 발생하였지만, CN7처럼 하나의 짧은 구간에 대부분의 불량이 집중되는 구조와는 차이

가 있음.

- 이에 단일 Cycle의 절대 공정값뿐 아니라 직전 생산 대비 변화 및 최근 생산상태와의 차이를 함께 분석할 필요가 있다고 판단함.

8) 생산 Session 구조 분석

- RG3 RH 데이터는 대부분 약 1분 간격으로 연속 생산되었으나 중간에 수시간 이상의 생산중단이 존재함.
- 생산중단 이전의 센서값을 이후 생산의 최근 상태로 사용할 경우 시간 기반 Feature가 실제 공정상태를 잘못 표현할 수 있음.
- 따라서 직전 생산과의 시간차가 30분 이상인 경우 새로운 생산 Session으로 정의함.

- 그 결과 총 5개의 생산 Session으로 구분됨.

Session	생산구간	데이터 수	불량
1	2020-10-21 00:16 ~ 00:57	41	**0**
2	2020-10-22 00:24 ~ 02:20	103	**5**
3	2020-10-22 04:40 ~ 08:09	197	**10**
4	2020-10-23 01:01 ~ 02:36	74	**4**
5	2020-10-23 04:41 ~ 07:46	176	**6**

- Session 사이에는 약 2시간에서 최대 23시간 이상의 생산공백이 존재함.
- 따라서 Lag, Diff, EWMA 등 시간 기반 Feature는 전체 생산기간을 단순 연결하지 않고 동일 Session 내부에서만 계산함.
- 이는 이전 생산일의 공정상태가 다음 생산 Session의 최근 상태로 잘못 사용되는 것을 방지하기 위한 처리임.

○ 3. 주요 변수 및 제조공정 의미

- 공정변수는 시간(Injection/Filling/Plasticizing/Cycle/Clamp Close), 위치(Cushion/Plasticizing Position), 속도(Injection Speed/Screw RPM), 압력(Injection/Switch Over/Back Pressure), 온도(Barrel/Hopper/Mold Temperature) 계열로 구분함.

- CN7은 현재 공정값·Side·최근 5 Cycle 평균상태를 함께 사용하고, RG3는 생산 Session별 기준점 이동을 고려해 절대값보다 최근 공정상태 대비 이탈 정도를 중심으로 분석함.
- SHAP 및 변수 중요도는 모델 예측 기여도를 의미하며 실제 불량의 물리적 원인으로 직접 해석하지 않음.

○ 4. 전처리 및 Feature Engineering

1) CN7

- labeled_data.csv로 TimeStamp·PART_NAME을 복원해 생산순서와 LH/RH 구조를 재구성함. 결측치가 없어 임의 보간은 수행하지 않았으며, 상수·ID성 변수는 모델 입력에서 제외함.
- 5분 초과 생산공백을 Session 경계로 정의하고, 시간 파생변수는 동일 Session 내부의 과거 Cycle만 사용함. 현재 Cycle 누수를 막기 위해 shift(1)을 적용함.
- Feature 비교 결과 현재 센서 23개 + Side_RH 1개 + 직전 5 Cycle 평균 23개를 최종 선택하여 총 47개 Feature를 구성함.
- TimeStamp를 Group으로 사용하는 StratifiedGroupKFold로 동일 Cycle의 LH/RH가 Train과 Validation에 동시에 포함되는 누수를 방지함.
- 모델 활용시점은 생산 Cycle 종료 후 최종 품질검사 이전이며, 공정 시작 전 사전예측이 아니라 검사 우선순위를 제공하는 Risk Ranking 문제로 정의함.

2) RG3

- 전체 불량 25건이 RH에서만 관찰되어 RH 591건(정상 566, 불량 25)만 지도학습 대상으로 사용하고 LH는 자동판정을 보류함.
- 이미 Standard Scaling된 데이터이므로 추가 Scaling을 적용하지 않았고, 상수변수 제거 후 23개 공정변수를 사용함.
- 30분 이상 생산공백을 기준으로 5개 Session을 구성하고 모든 시간 Feature는 동일 Session 내부에서만 생성함.
- Session별 변화 방향이 달라 최근 기준상태에서의 이탈 크기를 표현하는 Absolute EWMA Deviation을 비교했으며, 최종적으로 span=5의 23개

Absolute EWMA5 Feature를 사용함.

- Random CV의 과대평가 가능성을 줄이기 위해 생산순서를 유지하는 Rolling Temporal Validation을 최종 검증구조로 적용함.

○ 5. 핵심 데이터 문제 및 Target 진단

1) CN7

- 동일 Cycle의 LH/RH가 같은 센서값을 공유하면서도 품질결과가 달라질 수 있었고, 불량이 특정 시점에 집중되어 단순 행 단위 독립 분류로 보기 어려웠음.
- 불량 공정조건 그룹 14개 중 11개(78.6%)는 한쪽 Side만 불량이어서 센서만으로 부품 단위 결과를 완전히 결정하기 어려움을 확인함.
- 공정조건 그룹 Target은 데이터 구조 진단용으로만 검토했으며, 최종 LightGBM 학습 Target은 대회 제공 PassOrFail을 그대로 사용함.
- 내부 반복 CV의 높은 구분성능을 사전예측 성능으로 해석하지 않고 생산 완료 후 품질검사 우선순위를 제공하는 모델로 역할을 제한함.

2) RG3

- 불량률이 낮고(전체 2.12%, RH 4.23%) 모든 불량이 RH에 집중되어 전체 데이터를 그대로 학습하면 Side 기반 Shortcut Learning 위험이 있음.
- 생산 Session별 정상 기준점과 불량 변화방향이 달랐고 일부 변수는 고유값 수가 적어 공정 설정상태를 함께 반영할 가능성이 확인됨.
- Absolute EWMA5도 미래 Session에 따라 PR-AUC가 0.3136에서 0.0415로 크게 변동해 Random CV보다 시간순 검증을 우선함.

○ 6. 데이터 진단 결과와 모델 설계의 연결

1) CN7

데이터 진단 결과	모델링 반영
불량 비율 약 1.40%	Accuracy보다 PR-AUC, Recall, Precision 중심 평가
동일 Cycle의 LH/RH가 센서값 공유	TimeStamp기반 Group Validation
동일 공정에서도 Side별 품질 차이 존재	Side_RHFeature 추가
단순 직전 Cycle 변화보다 최근 상태가 중요	직전 5 Cycle Rolling Mean 사용
불량이 시간적으로 군집하여 발생	시간순 생산구조 유지
Failure Episode별 패턴 차이 존재	내부 CV뿐 아니라 미래 시점 Temporal Validation 병행
여러 센서가 동시에 변화	LightGBM 기반 다변량 비선형 모델 적용

- 최종적으로 CN7 데이터는 단순한 행 단위 이진분류 데이터가 아니라 생산 Cycle, Side, 시간적 공정이력, 공정상태 변화가 동시에 존재하는 시계열적 제조 품질 데이터로 정의함
- 데이터 구조를 반영하여 최종 입력변수는 현재 공정 센서 23개 + Side 정보 1개 + 직전 5 Cycle 평균 23개로 총 47개 Feature로 구성함

2) RG3

데이터 진단 결과	모델링 반영
전체 불량률 2.12%	Accuracy보다 PR-AUC, Recall, Precision 중심 평가
불량 25건이 모두 RH	**RH만 별도 모델링**, LH 자동판정 보류
PART_NAME과 RH_LH중복	모델 Feature에서 제외
Clamp_Open_Position상수	Feature 제거
Standard Scaling 적용	추가 Scaling 미적용
생산 중간에 장시간 공백 존재	**30분 기준 생산 Session 분리**
Session별 공정 기준점 변화	절대 센서값만 사용하지 않음
불량의 변화 방향이 Session별로 다름	**Absolute EWMA Deviation 생성**
최근 약 5 Cycle 이탈정보가 상대적으로 유효	**Absolute EWMA5 23개 Feature 검토**
Random CV와 미래 Session 성능 차이 큼	**Rolling Temporal Validation 적용**
불량 Cluster가 Session과 강하게 연관	불량유형으로 과도한 해석 금지

- 최종적으로 RG3는 단순히 591개의 독립적인 행으로 구성된 이진분류 데이터가 아니라 **생산 Session별 공정 기준점 이동과 시간적 공정상태 변화가 동시에 존재하는 제조 시계열 데이터**로 정의함.
- 특히 절대적인 센서값은 생산 Session 변화에 따라 의미가 달라질

수 있어 **현재 Cycle이 최근 생산상태에서 얼마나 벗어났는지를 표현하는 Dynamic Feature**를 중심으로 분석함.

- 이에 최종 분석에서는 PassOrFail을 유지하되 RH 데이터만 모델링 대상으로 사용하고, 생산 Session을 고려한 시간기반 검증을 통해 미래 생산구간 일반화 가능성을 확인하도록 설계함.

3) RG3 추가 Cycle 단위 Target 구조진단

- 기존 개발구간(2020-10-21~10-23)에서는 불량 25건이 모두 RH에서 관찰되었으나, 이후 2020-11-04 생산구간에서는 불량 7건 중 LH 5건, RH 2건으로 불량 Side 구조가 변화함.
- 동일 TimeStamp의 LH/RH가 동일한 공정센서값을 공유하므로 공정센서의 실제 관측단위는 제품 Side보다 생산 Cycle에 가까움. 따라서 Side 단위 PassOrFail만으로 공정상태와 품질결과의 관계를 설명하는 데 구조적 한계가 존재할 수 있다고 판단함.
- 이에 기존 RG3 최종모델의 Target과 결과는 유지하되, 추가 구조진단에서는 동일 Cycle에서 하나 이상의 불량제품이 발생하면 Cycle_Defect=1로 정의하여 센서 관측단위와 품질 Target 단위를 일치시킴.
- 본 Cycle-level 분석은 기존 Final Holdout 결과를 대체하기 위한 Target 변경이 아니라, 미래 실패와 Side 분포변화를 확인한 뒤 수행한 사후 구조진단으로 구분하여 해석함.

□ 제2장. AI 예측모델 개발 및 성능평가〔40점〕

- CN7과 RG3 데이터에 대해 각각 Baseline을 포함한 복수의 모델을 동일한 검증조건에서 비교하고, 데이터 특성에 적합한 최종 모델을 선정함.
- 두 차종은 데이터의 불량 분포와 시간적 특성, 공정변수의 분포가 서로 다르므로 하나의 모델을 공통 적용하지 않고 CN7과 RG3를 각각 독립적으로 모델링함.
- 모델 비교 시에는 Accuracy보다 불균형 데이터에 적합한 PR-AUC를 주요 평가기준으로 사용하였으며, 실제 현장 활용을 고려하여 Precision, Recall, F1 및 검사대상 비율을 함께 평가함.

○ 1. 공통 모델 개발 및 평가 기준

- CN7과 RG3 모두 정상 데이터에 비해 불량 데이터가 매우 적은 불균형 데이터이므로 일반 Accuracy만으로 모델을 평가할 경우 실제 불량탐지 능력을 적절히 판단하기 어려움
- 따라서 아래와 같은 평가 기준을 공통적으로 적용함

평가항목	활용 목적
PR-AUC	불균형 데이터에서 모델의 전반적인 불량 위험 순위화 성능
Precision	불량으로 판단한 제품 중 실제 불량 비율
Recall	실제 불량 중 모델이 탐지한 비율
F1-score	Precision과 Recall의 균형
F2-score	Recall에 더 높은 가중치를 부여한 평가
Flag Rate	전체 생산품 중 검사대상으로 지정되는 비율

- 또한 모델 간 성능 차이를 공정하게 비교하기 위해 각 데이터셋 내에서는 동일한 Feature set과 동일한 검증조건을 적용함
- 단, CN7과 RG3는 데이터 생성구조와 시간 분포가 서로 다르므로 각 데이터 특성에 맞는 검증 및 Feature Engineering을 별도로 수행함

○ 2. CN7 예측 모델 개발

① CN7 모델 개발 방향

- CN7은 총 1,211개 학습 데이터 중 정상 1,194건, 불량 17건으로 구성되

어 있으며 불량 비율은 약 1.40%임.

- 앞선 데이터 진단에서 현재 공정센서뿐 아니라 제품 Side와 최근 생산 Cycle의 공정상태가 불량위험을 설명하는 데 중요한 것으로 확인됨
- 이에 따라 CN7 최종 후보 Feature는 현재 공정센서 23개 + Side_RH 1개 + 직전 5 Cycle roll5_mean 23개 = 총 47개로 구성하였음.

② CN7 검증 조건

- 동일 생산 Cycle의 LH/RH가 동일한 공정센서값을 공유하는 특성을 고려하여 TimeStamp를 Group으로 사용하는 4-Fold StratifiedGroupKFold를 적용함
- 이를 통해 동일 Cycle의 데이터가 Train과 Validation에 동시에 포함되는 데이터 누수를 방지함

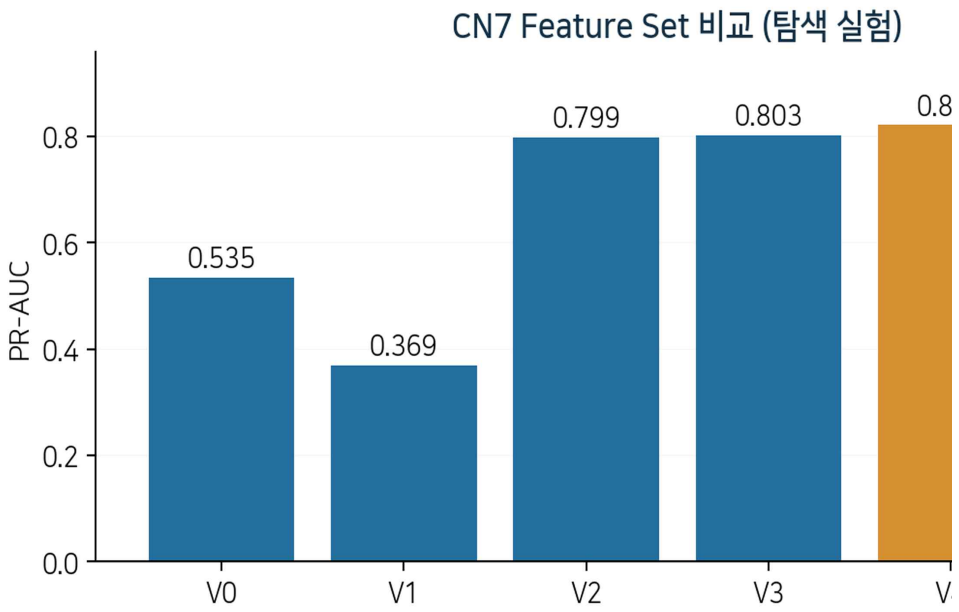
항목	설정
Validation	StratifiedGroupKFold
Fold	4
Group	TimeStamp
주요 평가항목	PR-AUC
보조 평가항목	Precision, Recall, F1, F2
입력 Feature	47개

③ CN7 Feature set 비교

- CN7에서는 현재 센서값뿐 아니라 시간적 공정정보를 어느 수준까지 반영할 것인지 확인하기 위해 Feature Ablation을 수행함

Feature Set	구성	Feature 수	PR-AUC
V0	Original + Side	24	0.535
V1	V0 + Diff	47	0.369
V2	V1 + Rolling Mean	70	0.799
V3	V2 + Rolling Std	93	0.803
V4	V3 + Deviation	116	0.822
V5	**Original + Side + Rolling Mean**	**47**	**0.805**

- V4의 PR-AUC가 가장 높았으나 Feature 수가 116개로 증가하였으며, Recall과 F1을 포함한 운영성능에서는 V5가 더 안정적인 결과를 보였음.



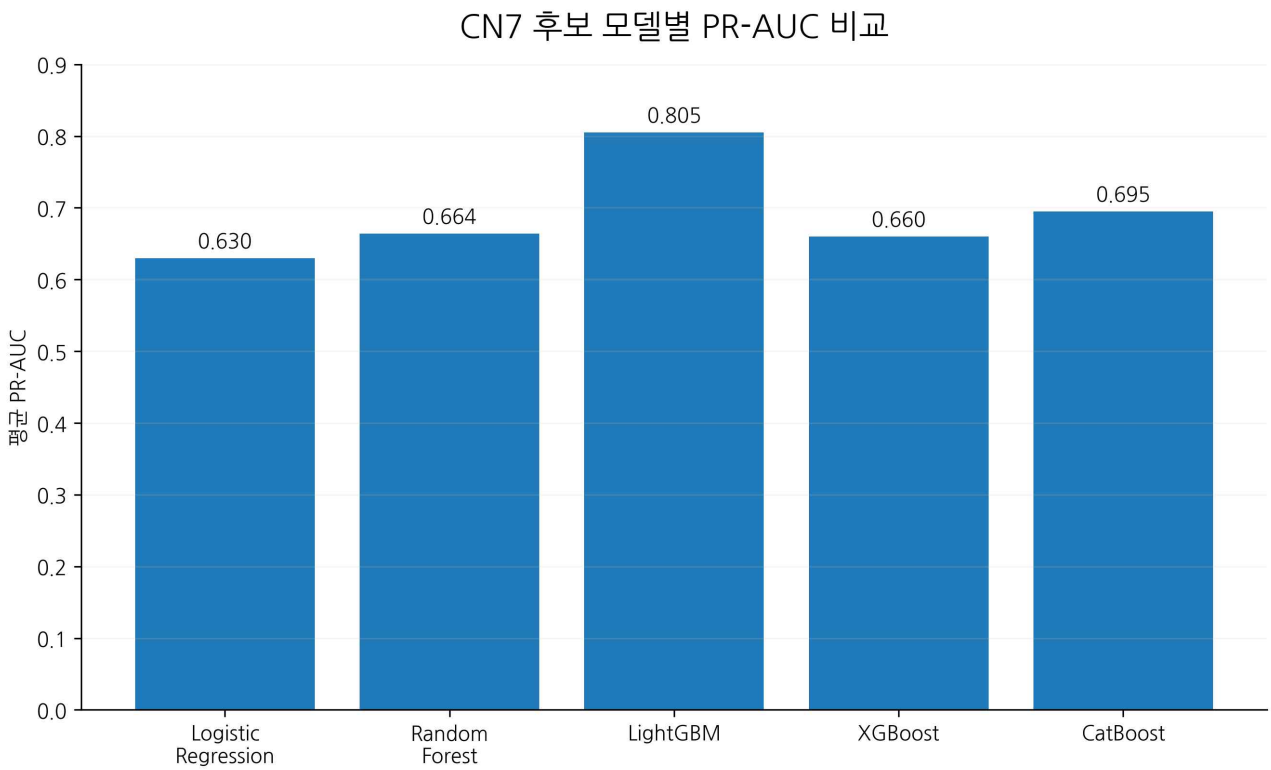
V4: 최고 PR-AUC / V5: 47개 변수·운영 해석성 고려하여 채택

- 따라서 성능, Feature 수, 과적합 가능성 및 해석성을 종합하여 V5 Feature Set을 최종 채택함.

④ CN7 후보 모델 비교

- V5 Feature 47개를 동일하게 사용하여 Baseline 모델을 포함한 여러 알고리즘을 비교함
- Baseline인 Logistic Regression과 비교했을 때 Tree 기반 Ensemble 모델에서 전반적인 성능 향상이 나타남.
- 특히 LightGBM은 PR-AUC 약 0.805로 가장 높은 성능을 기록하였으며 F1 역시 가장 높았음.
- 따라서 이후 불균형 처리 및 하이퍼파라미터 최적화는 LightGBM을 기준으로 수행함.

Model	평균 PR-AUC	평균 Recall	평균 F1
Logistic Regression	약 0.630	0.350	0.435
Random Forest	약 0.664	0.350	0.476
LightGBM	**약 0.805**	0.513	**0.633**
XGBoost	약 0.660	0.413	0.500
CatBoost	약 0.695	**0.525**	0.616



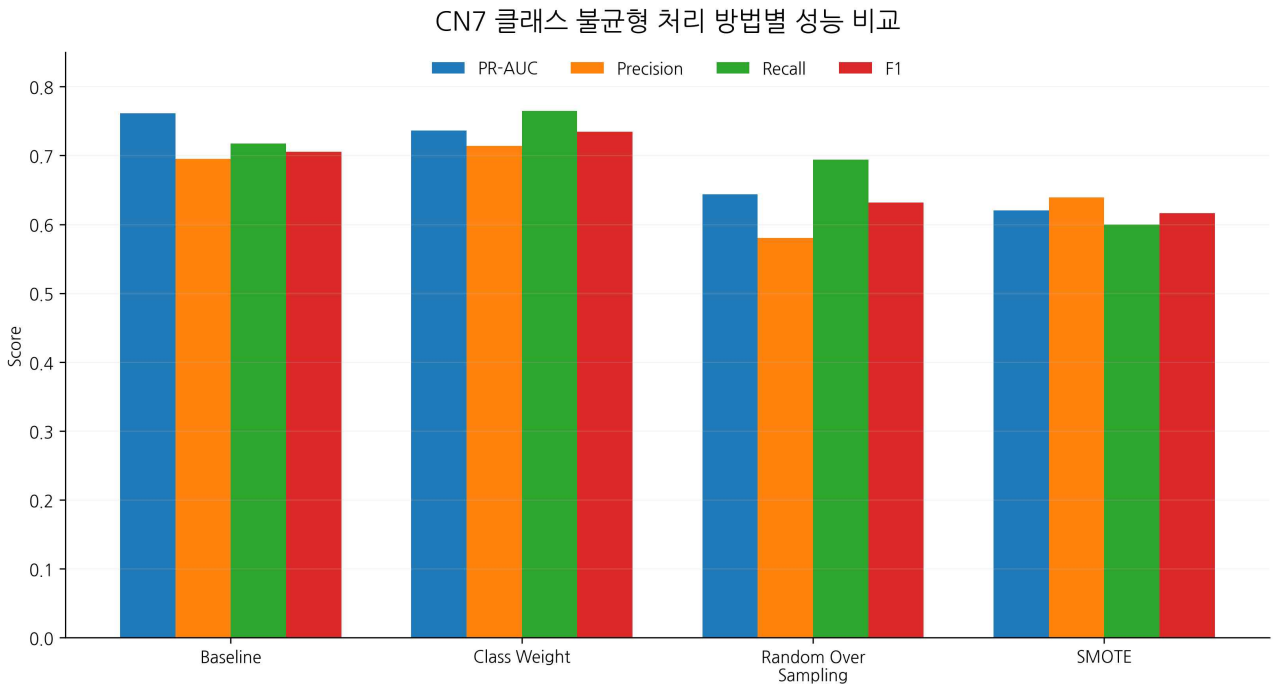
⑤ CN7 클래스 불균형 처리 비교

방법	PR-AUC	Precision	Recall	F1
Baseline	0.7613	0.6950	0.7176	0.7051
Class Weight	0.7360	**0.7137**	**0.7647**	**0.7343**
Random Over Sampling	0.6436	0.5803	0.6941	0.6316

- Baseline LightGBM의 PR-AUC 자체는 높았으나 Class Weight 적용 시 Recall과 F1이 개선됨.
- 목표는 불량 미탐을 최소화하는 것이 중요한 목표이므로 최종 모델에는 Class Weight 방식을 적용함.
- 반면 Random Over Sampling과 SMOTE는 소수 불량 샘플을 복제하거나 합성하면서 성능변동이 증가하여 최종 방식에서는 제외함.

⑥ CN7 하이퍼파라미터 최적화

- LightGBM + Class Weight를 기준으로 하이퍼파라미터 탐색을 수행함.
- 30개의 Parameter 조합을 생성한 후 5개 Seed × 4-Fold StratifiedGroupKFold 조건으로 반복평가함.



Parameter	값
n_estimators	200
learning_rate	0.10
num_leaves	15
max_depth	7
min_child_samples	10
subsample	1.0
colsample_bytree	0.70
class_weight	balanced

- 최종 반복검증 결과 PR-AUC는 0.8164 ± 0.0181으로 나타남

<5-Seed 개별 OOF 기준 Threshold 성능 평균>

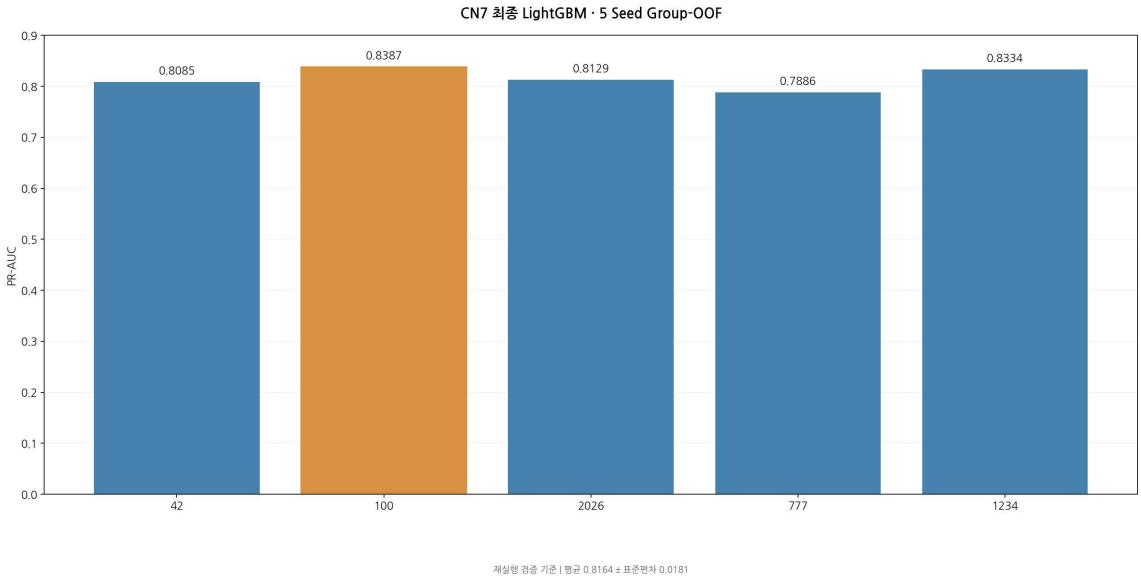
Threshold	Precision	Recall	F1	F2
0.020	0.6923	**0.8118**	0.7460	**0.7837**
0.060	0.7122	0.7647	0.7351	0.7519
0.080	**0.7085**	0.7529	**0.7278**	0.7421

⑦ CN7 Threshold 최적화

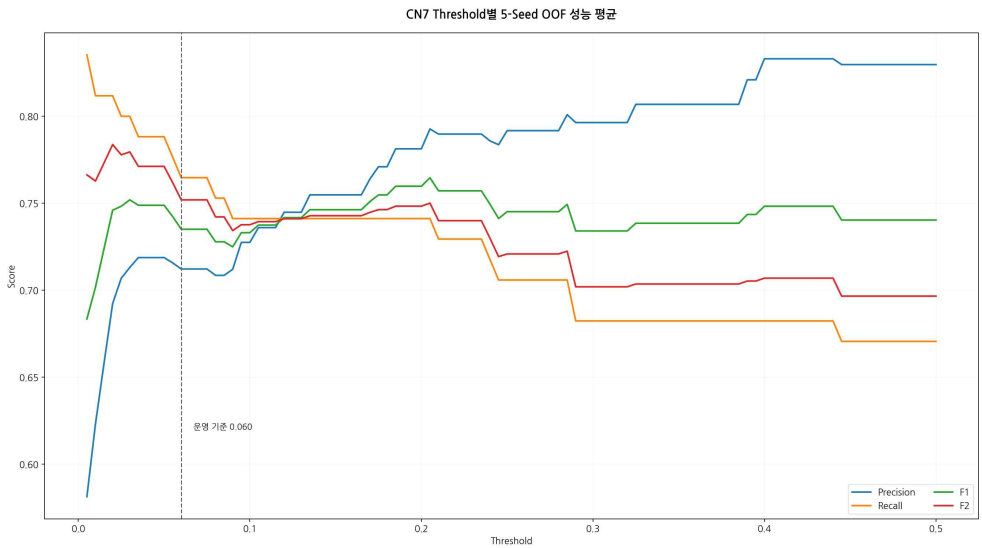
- 모델의 위험확률을 실제 검사대상 선정으로 연결하기 위해 Threshold를 별도로 최적화함

- 아래 Threshold별 성능은 5개 Random Seed에서 각각 생성된 OOF

Prediction에 동일 Threshold를 적용하여 성능지표를 계산한 후, Seed 별 결과를 평균한 값임.



- Recall을 최대화하면 검사대상이 증가하고 Precision이 감소하는 Trade-off가 발생함.



- 5-Seed 개별 OOF 성능 평균 기준 Threshold 0.060에서 Precision 0.7122, Recall 0.7647을 기록함. 이에 Precision과 Recall의 균형 및 검사대상 규모를 고려하여 0.060을 Ensemble Risk Score에도 적용할 운영 Threshold 후보로 선정함.

⑧ CN7 최종 모델

항목	최종 설정
Model	**LightGBM**
Feature	Original + Side + Roll5 Mean
Feature 수	47
불균형 처리	Class Weight
Validation	4-Fold StratifiedGroupKFold
반복검증	5 Seeds
5-Seed 반복 Group-OOF PR-AUC	0.8164 ± 0.0181
Threshold	**0.060**
5-Seed 개별 OOF 평균 Precision	0.7122
5-Seed 개별 OOF 평균 Recall	0.7647
5-Seed 개별 OOF 평균 F1	0.7351
5-Seed 개별 OOF 평균 F2	0.7519

- LightGBM은 Baseline을 포함한 모델 비교에서 가장 높은 PR-AUC를 보였으며, 시간적 공정이력과 현재 공정센서 사이의 비선형 관계를 효과적으로 학습할 수 있었음
- 또한 반복 Seed 검증에서도 낮은 성능편차를 보여 최종 CN7 위험도 예측모델로 선정함

⑨ CN7 Future Failure Regime 및 PCA-OOD 안전계층 검증

- 내부 Group-OOF 성능과 별도로 미래 생산구간 E4(2020-10-27), E5(2020-11-03)를 시간순으로 검증한 결과, 기존 LightGBM Risk와 Ensemble Uncertainty는 두 구간의 불량 Cycle을 탐지하지 못해 신규 Failure Regime 일반화 한계가 확인됨.
- 이에 미래 불량 라벨을 학습이나 Threshold 결정에 사용하지 않고, 각 Future Fold 이전의 정상 Cycle만으로 RobustScaler + PCA(설명분산 95%)를 학습한 뒤 정상 Calibration 구간 Reconstruction Error의 99 percentile을 OOD Threshold로 설정함.
- E4에서는 총 314 Cycle 중 4 Cycle(1.27%)만 OOD로 경보했으며, 5개 불량 Cycle 중 4개를 포착하여 Precision 100%, Recall 80%, F1 0.8889를 기록함.
- E5에서는 463 Cycle 중 6 Cycle을 OOD로 경보했으나 실제 불량 1

Cycle은 포착하지 못해 Recall 0%로 나타남. E5의 관측된 불량 1 Cycle은 제공 센서 공간에서 정상과 유사한 사례로 나타났으며, 단일 사례이므로 일반화하지 않음.

- 본 OOD 분석은 E4/E5에서 기존 모델의 실패를 확인한 뒤 수행한 사후 안전성 보완실험이며, 독립적인 최종 성능검증을 대체하지 않고 Failure Regime 변화 대응 가능성을 확인하는 보완 결과로 사용함.

○ 3. RG3 예측 모델 개발

1) RG3 모델 개발 방향

- RG3는 전체 1,182개 데이터 중 정상 1,157건, 불량 25건으로 불량 비율이 약 2.12%인 불균형 데이터임.
- 데이터 구조 분석 결과 전체 불량 25건이 모두 RH에서 발생하고 LH에서는 불량이 관찰되지 않았으므로, 최종 지도학습 모델은 RH 591건을 대상으로 개발함.
- RH 데이터는 정상 566건, 불량 25건으로 구성되며 불량 비율은 약 4.23%임.
- RG3에서는 생산 Session에 따라 정상 공정의 기준점과 불량 발생 시 센서 변화방향이 달라지는 현상이 확인됨.
- 따라서 단순한 Random Split 성능을 최대화하는 것보다 과거 생산 Session에서 학습한 모델이 이후 생산 Session에서도 불량위험을 구분할 수 있는지를 중요하게 평가함.
- 모델 개발 과정에서는 다음 순서로 성능을 개선함.

Original Feature Baseline
→ 일반 시간 파생변수 비교
→ 반복 교차검증 및 불균형 처리
→ Dynamic Feature 개발
→ EWMA 기반 Local Baseline
→ Absolute EWMA5 선정
→ 모델 비교
→ 미래 Session 검증
→ 최종 Holdout 및 Rolling Temporal Validation

2) RG3 학습 및 검증 데이터 구성

- 실제 미래 생산환경을 최대한 반영하기 위해 생산 Session을 기준으로 Development와 Holdout을 분리함.
- Session 1~3은 모델 및 Feature 개발에 사용하고, Session 4~5는 최종 시간 일반화 성능을 확인하기 위한 Holdout으로 설정함.

구분	Session	정상	불량	전체
Development	1~3	326	15	**341**
Final Holdout	4~5	240	10	**250**

- 초기 Feature 및 모델 비교에서는 다음과 같이 시간순으로 분리함.

구분	데이터
Train	Session 1~2
Validation	Session 3
Final Holdout	Session 4~5

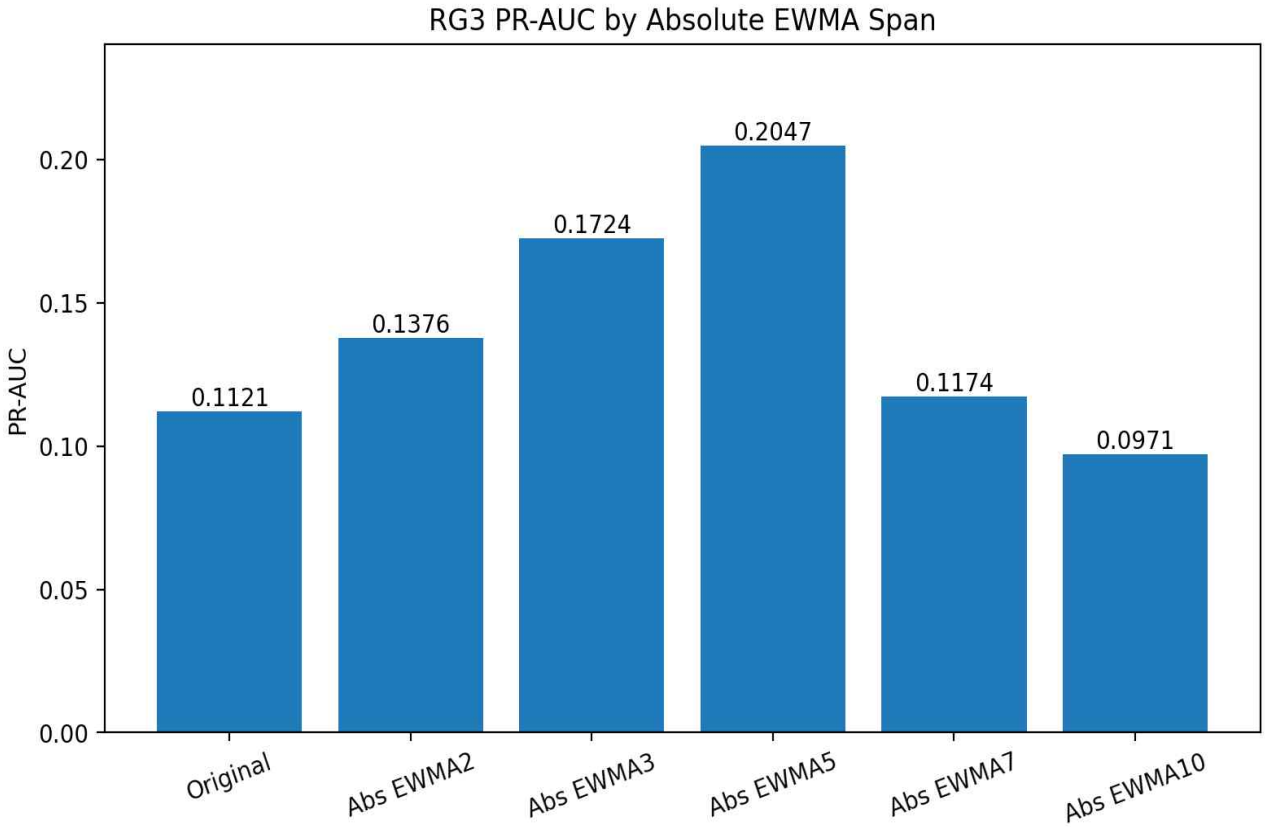
- Session 1~2 Train 데이터는 정상 139건, 불량 5건으로 구성됨.
- Session 3 Validation 데이터는 정상 187건, 불량 10건으로 구성됨.
- Validation 불량률은 약 **5.1%**임.
- 따라서 PR-AUC가 약 0.05 수준이면 실제로는 Random 수준에 가까운 성능으로 해석함.

3) Baseline 및 Dynamic Feature 탐색

- Original Feature 기반 미래 Session 성능은 낮았으며(Logistic Regression PR-AUC 0.0358, Random Forest 0.0484), 일반 Lag · Diff · Rolling 계열도 뚜렷한 개선을 만들지 못함.
- 반복 CV에서 XGBoost가 Original 기준 평균 PR-AUC 0.1121을 보였고, Oversampling/SMOTE보다 최근 기준상태를 표현하는 Feature Engineering이 더 중요하다고 판단함.
- EWMA Deviation이 상대적으로 개선을 보였고, Session별 불량 변화방향이 반대인 문제를 고려하여 방향 대신 이탈 크기를 사용하는 Absolute EWMA를 최종 후보로 검토함.

4) Absolute EWMA Deviation Feature 선정

- Absolute EWMA Deviation은 각 센서값이 직전 공정의 EWMA 기준 상태에서 얼마나 크게 벗어났는지를 절대값으로 표현함.
- Repeated Stratified Cross Validation에서 Span별 성능은 다음과 같음.



Feature Set	PR-AUC Mean	PR-AUC Std	ROC-AUC Mean
Original + Abs EWMA5	**0.2047**	0.1530	**0.6645**
Original + Abs EWMA3	0.1724	0.1066	0.6235
Original + Abs EWMA2	0.1376	0.1057	0.5914
Original + Abs EWMA7	0.1174	0.0735	0.5870
Original	0.1121	0.0879	0.5856
Original + Abs EWMA10	0.0971	0.0748	0.5535

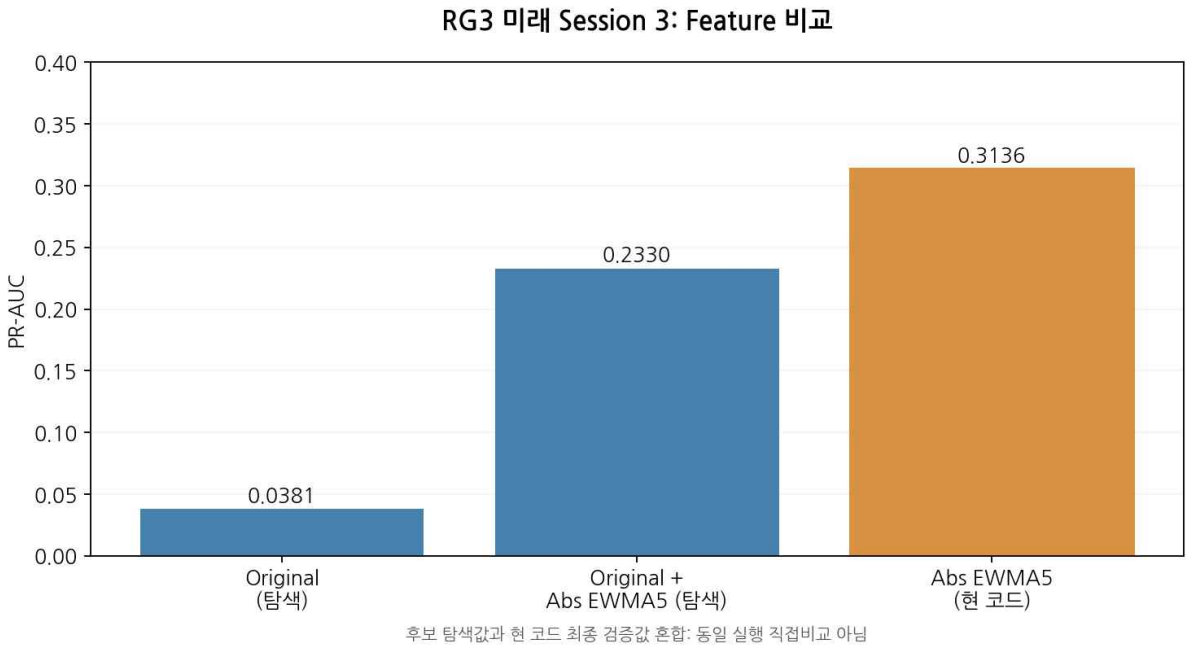
- Absolute EWMA5에서 가장 높은 평균 PR-AUC인 **0.2047**을 기록함.
- Original Feature 대비 PR-AUC가 **0.1121 → 0.2047**, 약 **82.6% 증가**함.
- 동일한 30개 Fold 중 Absolute EWMA5가 Original보다 높은 성능을 기록한 Fold는 **23개**, Original이 우세한 Fold는 7개였음.
- 이에 최근 **약 5 Cycle의 공정상태를 기준으로 현재 Cycle의 이탈크**

기를 표현하는 Feature가 RG3에서 가장 유효한 시간정보로 판단함.

5) 미래 Session에서 Feature 표현방식 검증

- Random Cross Validation에서는 서로 다른 생산 Session이 Train과 Validation에 동시에 포함될 수 있으므로, Absolute EWMA5가 실제 미래 생산에서도 효과적인지 확인함.

검증조건:
Train: Session 1~2
Validation: Session 3



Feature Set	PR-AUC	ROC-AUC
Abs EWMA5 Only	**0.3136**	**0.6642**
Original + Abs EWMA5	0.2330	0.5385
Original	0.0381	0.3107

- 미래 Session 검증에서는 **Absolute EWMA5 Feature만 사용한 모델이 가장 높은 성능**을 기록함.
- Original Feature만 사용할 경우 PR-AUC가 0.0381이었으나 Abs

EWMA5 단독에서는 0.3136으로 약 8.2배(현 코드 재실행 기준) 상승함.

- Original과 Absolute EWMA를 함께 사용할 경우 오히려 성능이 감소함.
- 이는 생산 Session이 변경될 때 센서의 절대 기준값 자체가 이동하여 Original Feature가 미래 일반화를 방해했을 가능성을 보여줌.
- 따라서 최종 Feature는 **23개 Absolute EWMA5 Feature만 사용**하도록 선정함.

6) Absolute EWMA5 기반 후보 모델 비교

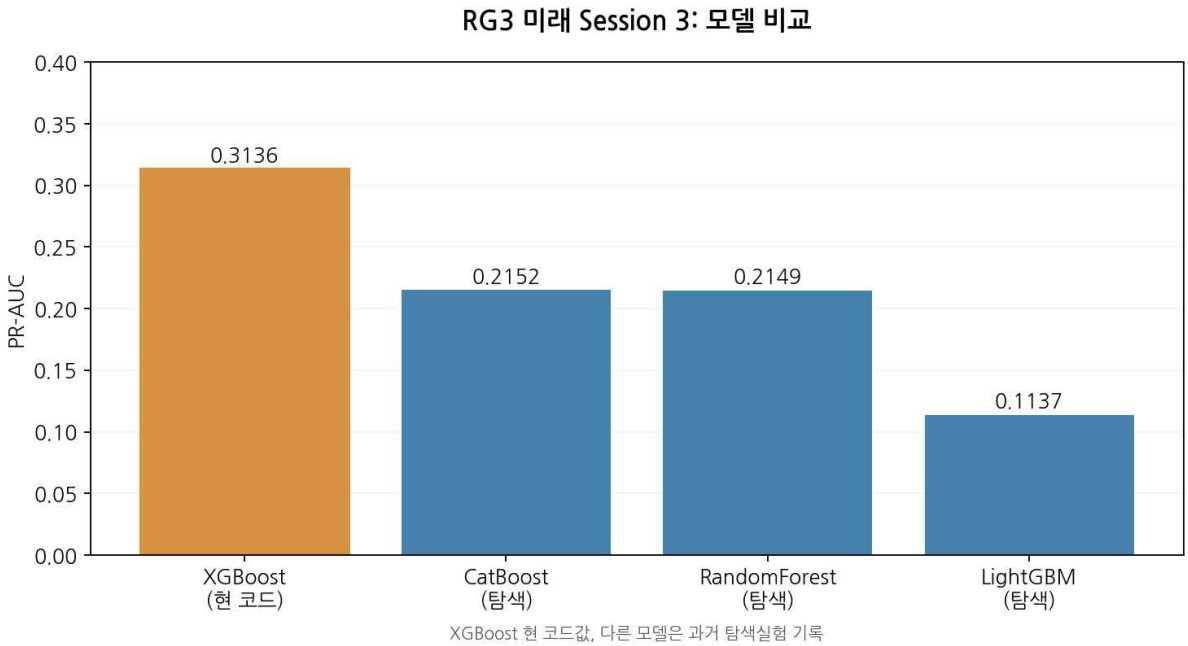
- 최종 Feature를 Absolute EWMA5로 고정하고 여러 분류 알고리즘을 동일하게 비교함.
- Repeated Stratified Cross Validation

Model	PR-AUC Mean	ROC-AUC Mean
LightGBM	**0.2055**	**0.7056**
CatBoost	0.1970	0.6909
XGBoost	0.1902	0.7014
Random Forest	0.1778	0.6914

- Random Cross Validation에서는 LightGBM이 평균 PR-AUC 0.2055로 가장 높은 성능을 보임.
- 그러나 본 과제의 목적은 이후 생산되는 데이터에 대한 불량위험 선별이므로 **미래 Session 성능을 추가 비교**함.
- 미래 Session 모델 비교 (타 모델은 이전 탐색 기록)
- Train은 Session 1~2, Validation은 Session 3으로 고정함.

Model	PR-AUC	ROC-AUC
XGBoost	**0.3136**	**0.6642**
CatBoost	0.2152	0.6620
Random Forest	0.2149	0.6508
LightGBM	0.1137	0.6070

- Random CV에서는 LightGBM이 가장 높았지만, 미래 Session 검증에서는 XGBoost가 가장 높은 성능을 기록함.
- 본 과제에서는 Random Split 평균성능보다 **시간적으로 이후에 생산된 데이터에서의 일반화 성능을 더 중요하게 판단**함.



- 이에 최종 모델 후보를 다음과 같이 선정함.

항목	최종 후보 설정
Model	**XGBoost**
Feature	**Absolute EWMA5 Only**
Feature 수	**23개**
EWMA Span	**5 Cycle**
불균형 처리	scale_pos_weight
n_estimators	300
max_depth	3
learning_rate	0.03
subsample	0.8
colsample_bytree	0.8
random_state	42

7) Recall과 검사부담 Trade-off

- 높은 Recall을 확보할수록 검사대상이 급증했으며, Recall 100%에는 180/197건(91.4%) 검사가 필요해 자동 검사량 절감 모델로 사용하기 어

렵다고 판단함.

지표	결과
Threshold	**0.002587**
Precision	0.0556
Recall	**1.0000**
F1	0.1053
검사대상	180 / 197
검사율	**91.4%**
TP	10
FP	180
FN	**0**

- 따라서 RG3는 고정 Threshold 기반 자동판정보다 상대적 Risk Ranking 용도로 활용함.

8) 최종 Holdout 평가

- 모델 및 Feature 선택을 완료한 후 Session 1~3 전체를 학습하고, 모델 개발에 사용하지 않은 Session 4~5를 Final Holdout으로 평가함.

구분	정상	불량	전체
Train: Session 1~3	326	15	341
Holdout: Session 4~5	240	10	250

- 최종 XGBoost + Absolute EWMA5 성능은 다음과 같음.

평가항목	결과
Holdout 불량률	**0.0400**
PR-AUC	0.0415
ROC-AUC	0.4254
PR Lift	1.037

- Session 1~2 → Session 3 검증에서는 PR-AUC 0.3136을 기록했으나 Session 1~3 → Session 4~5 Holdout에서는 0.0415로 크게 감소함.
- Holdout 불량률 0.0400 대비 PR-AUC는 0.0415, PR Lift는 1.037배로

나타나 무작위 순위화 수준과 거의 유사했으며 운영에 사용할 만큼 안정적인 선별효과는 확인되지 않음.

- 즉 Absolute EWMA5 + XGBoost가 특정 미래 Session에서는 유효했지만, 이후 모든 생산 Session에서 동일하게 일반화되는 패턴은 아니었음.

9) Rolling Temporal Validation

- Final Holdout 결과에서 큰 성능저하가 확인되었으므로 특정 한 개 Holdout 구간만으로 결론을 내리지 않고 전체 생산 Session을 이용한 Rolling Temporal Validation을 추가 수행함.
- 검증구조는 다음과 같음.

Fold	Train Session	Validation Session
1	1~2	3
2	1~3	4
3	1~4	5

XGBoost + Absolute EWMA5 결과:

Fold	Validation 수	불량 수	불량률	PR-AUC	PR Lift	ROC-AUC
1	197	10	5.08%	0.3136	**6.178**	0.6642
2	74	4	5.41%	0.0465	**0.860**	0.2964
3	176	6	3.41%	0.0961	**2.819**	0.7520

- Fold 1에서는 높은 Ranking 성능을 보였으나 Fold 2에서는 Random 수준 이하로 감소함.
- Fold 3에서는 PR Lift가 2.82로 일부 Ranking 효과가 나타났으나 절대 PR-AUC는 0.0961로 낮음.
- 생산 Session에 따라 성능변동이 매우 크게 나타났으며, **안정적인 미래 일반화 성능이 확보되었다고 판단하기 어려움.**

10) RG3 최종 모델 및 성능평가 종합

항목	결과
모델링 대상	RG3 RH 591건
Target	PassOrFail
핵심 Feature	**Absolute EWMA5 23개**
후보 모델	**XGBoost**
개발 반복 CV	Feature/model 탐색용
미래 Session 선택 성능	PR-AUC 0.3136, ROC-AUC 0.6642
Final Holdout	PR-AUC 0.0415, ROC-AUC 0.4254
Rolling Temporal	PR-AUC 0.3136 / 0.0465 / 0.0961
현장 판정 가능성	**안정적 자동 불량판정에는 한계**

- RG3에서는 Original Feature 기반 모델보다 **최근 5 Cycle 기준상태에서의 절대 이탈 정도를 나타내는 Absolute EWMA5 Feature가 반복적으로 더 높은 성능**을 보임.
- 특히 Session 1~2 → Session 3에서는 PR-AUC 0.3136로 Original Feature의 0.0381보다 크게 개선됨.
- 그러나 최종 Holdout과 Rolling Temporal Validation에서 성능이 크게 변동하여 **미래 생산 Session 전반에 대해 안정적으로 일반화되는 모델은 확보하지 못함.**
- 따라서 RG3 결과는 높은 단일 성능을 최종 성과로 제시하기보다, **생산 Session에 따른 공정분포 변화와 모델 일반화 한계를 확인한 결과**로 해석함.
- 최종 XGBoost + Absolute EWMA5 구조는 이후 제3장에서 **어떤 조건에서 모델이 작동하고 어떤 조건에서 실패하는지 분석하기 위한 기준 모델**로 활용함.

11) RG3 추가 Cycle-level 외부 시간구간 구조진단

- Robust Z5/10/20 및 Normalized EWMA Std5/10/20을 기존 Absolute EWMA5와 동일한 Rolling Temporal Validation으로 비교했으나, 모든 후보가 3개 Fold 중 1개 Fold에서만 개선되어 채택조건을 만족하지 못함. 따라서 기존 Absolute EWMA5 23개 Feature를 유지함.
- Cycle-level 추가 분석은 2020-10-21~10-23의 586 Cycle(불량 25 Cycle)

을 학습하고, 이후 2020-11-04의 35 Cycle(불량 7 Cycle)을 추가 시간 구간으로 평가함.

- Absolute EWMA5 + XGBoost의 2020-11-04 Cycle-level 결과는 제출 ZIP의 rg3_cycle_oot_metrics.csv 기준 PR-AUC 0.4124, ROC-AUC 0.6637, 불량률 0.2000 대비 PR Lift 2.06배로 나타나 무작위 순위보다 높은 위험순위 신호를 확인함.
- Risk 상위 20%인 7 Cycle을 검사하면 7개 불량 Cycle 중 2개를 포착하여 Precision 28.57%, Recall 28.57%를 기록했고, 상위 40%인 14 Cycle 검사 시 불량 5개를 포착하여 Recall 71.43%, 상위 50%에 해당하는 18 Cycle 검사 시에도 5개를 포착하여 Recall 71.43%를 기록함.
- 다만 높은 Recall을 위해 검사율이 크게 증가하므로 자동 불량판정이나 검사량 대폭 절감 성과로 해석하지 않고, Cycle 단위 Risk Ranking의 제한적 가능성을 확인한 보완 결과로 사용함.
- 또한 본 분석은 기존 미래 Session 실패와 11/04 Side 변화 확인 이후 수행한 Post-hoc External Temporal Analysis이므로, 기존 Final Holdout PR-AUC 0.0415을 대체하는 독립 최종검증으로 제시하지 않음.

□ 제3장. 영향요인 및 오류분석〔15점〕

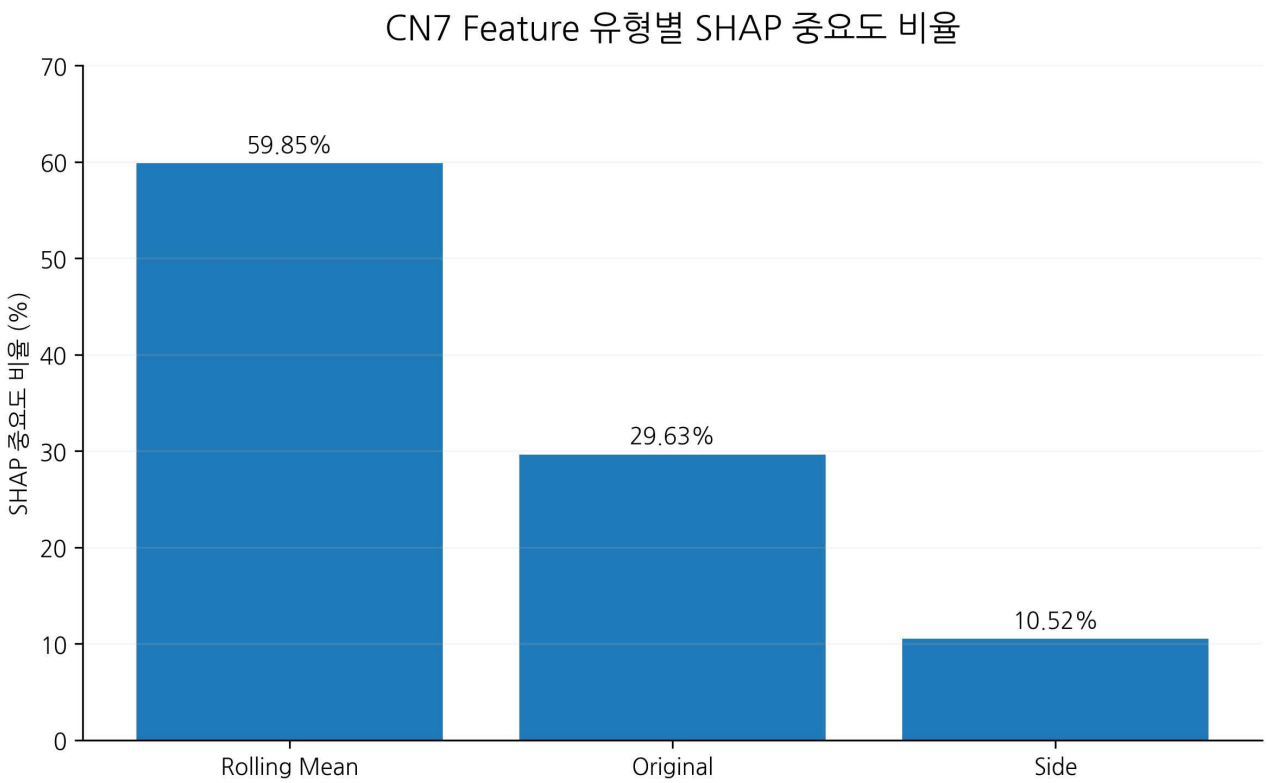
- 평균 성능만 제시하지 않고 모델이 작동하는 조건과 실패하는 조건을 구분하고, 미탐·오경보·분포 이동을 중심으로 분석함.

○ 1. CN7 영향요인 및 오류분석

① 모델 예측 기여요인 분석

- Feature 유형별 절대 SHAP 값을 합산한 결과, 직전 5 Cycle Rolling Mean 계열이 전체 모델 예측 기여도의 59.85%를 차지함.
- 전체 Feature 중요도를 유형별로 구분한 결과 다음과 같이 나타남.

Feature 유형	SHAP 중요도 비율
직전 5 Cycle Rolling Mean	**59.85%**
Original Sensor	29.63%
Side	10.52%



- 전체 중요도의 약 60%가 직전 5 Cycle의 평균 공정상태에서 발생함.
- 이는 CN7의 불량위험 판단에서 현재 Cycle의 순간적인 센서값뿐 아니라 불량 발생 이전 최근 여러 Cycle 동안 형성된 공정상태가 중요한 정보로 작용했음을 의미함.

- 개별 Feature의 SHAP 중요도는 다음과 같음.

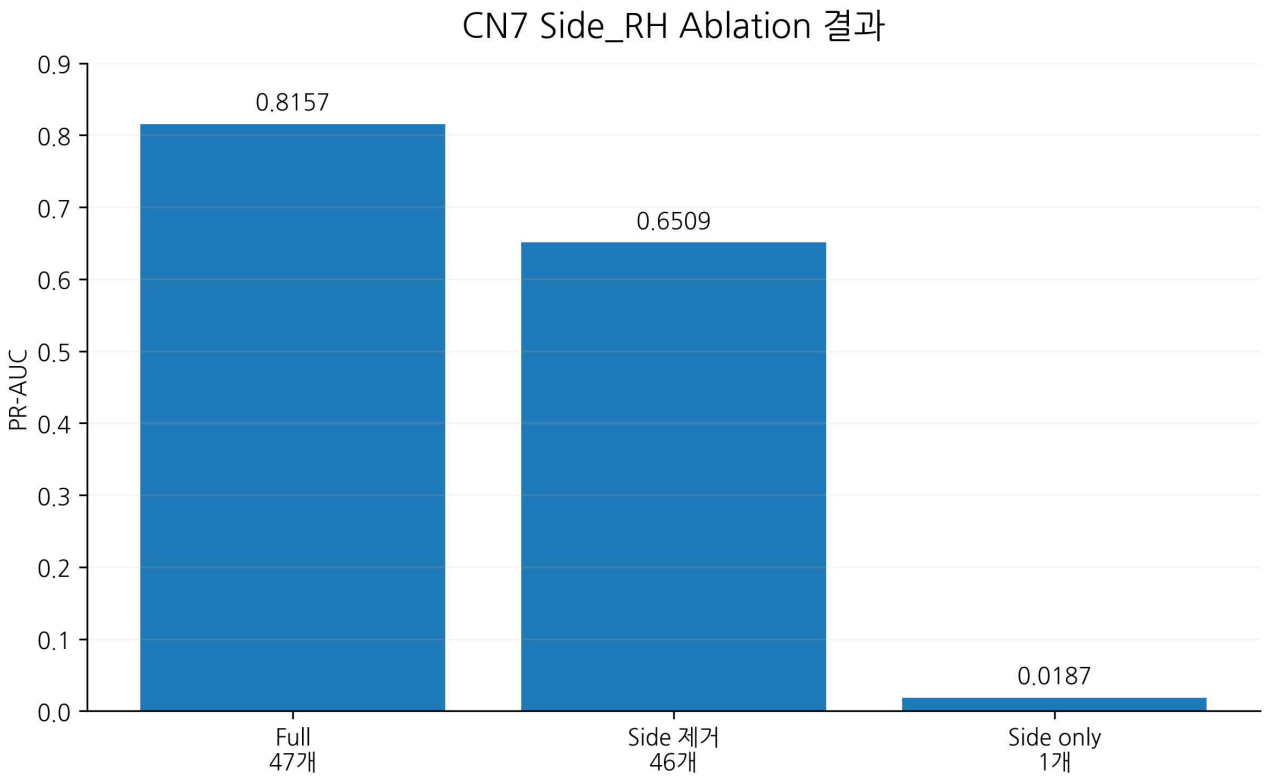
순위	Feature	Mean |SHAP|
1	Side_RH	0.6191
2	Mold_Temperature_3_roll5_mean	0.5418
3	Plasticizing_Position	0.4676
4	Max_Screw_RPM_roll5_mean	0.4523
5	Mold_Temperature_4_roll5_mean	0.4298
6	Hopper_Temperature_roll5_mean	0.3578
7	Clamp_Close_Time	0.3551
8	Barrel_Temperature_2_roll5_mean	0.3546
9	Clamp_Close_Time_roll5_mean	0.3169

- 특히 Mold_Temperature_3/4, Screw RPM, Hopper Temperature 등에서 최근 공정상태를 나타내는 Rolling Mean Feature가 상위에 다수 포함됨.
- 이는 특정 순간의 센서 이상보다 최근 수 Cycle 동안 지속된 금형온도, 스크류 작동상태 및 설비조건의 변화가 모델의 위험도 판단에 크게 작용했음을 보여줌.
- SHAP 값은 모델 예측에 대한 Feature의 기여도를 설명하는 값으로, 해당 공정변수가 실제 불량을 물리적으로 발생시키는 원인임을 의미하지 않음.

② Side_RH 영향 검증

- SHAP 분석에서 Side_RH가 가장 높은 개별 중요도를 보였기 때문에, 이를 그대로 “RH가 불량의 원인“이라고 해석할 경우 잘못된 결론으로 이어질 수 있음.
- 이에 따라 Side 정보를 제거한 모델과 Side 정보만 사용한 모델을 별도 Ablation 실험 조건으로 비교함. 아래 Full Model 수치 0.8157은 이 탐색 실험의 비교기준이며 제2장의 최종 5-Seed OOF 평균 0.8164와 다른 평가 실행 결과임.

모델	Feature 수	PR-AUC
Full Model	47	**0.8157**
Side 제거	46	0.6509
Side_RH Only	1	**0.0187**



- 별도 Ablation 탐색 실험에서 Side_RH를 제거하면 PR-AUC가 0.8157 → 0.6509로 감소하여 Side 정보가 최종 판별에 실질적으로 기여하고 있음을 확인함.
- 반면 Side 하나만 사용한 모델의 PR-AUC는 0.0187에 불과함.
- 따라서 Side는 단독으로 불량을 결정하는 원인변수가 아니라, 제품 위치 + 공정조건 + 최근 공정이력 사이의 상호작용을 구분하는 보조 Feature로 해석함.
- 즉 "RH이기 때문에 불량이다" 라는 인과적 해석은 하지 않았으며, 동일 공정조건에서 발생할 수 있는 제품 위치별 차이를 모델에 제공하는 변수로 사용함.

③ CN7 미탐 및 오경보 분석

- 실제 검사정책을 모의 평가하기 위해 5개 Seed에서 생성된 OOF Probability를 평균하여 Ensemble Risk Score를 구성하고, Threshold 0.060을 적용하여 미탐과 오경보를 분석함.

3) 모델이 상대적으로 잘 작동한 조건

- 내부 OOF에서는 E1~E3처럼 학습구간과 유사한 Failure Regime에서 높은 판별력을 보였으며, 반복 Group-CV PR-AUC는 0.8164 ± 0.0181임. 이 수치는 미래 모든 불량형태의 일반화 성능이 아니라 내부 판별성능으로 해석함.

<5-Seed Ensemble Risk Score 기반 정책 Simulation>

지표	결과
TP	14
FP	7
FN	**3**
TN	1,187
Precision	66.67%
Recall	**82.35%**
검사대상	21건
검사율	**1.73%**

- 제2장의 Recall 76.47%는 5개 Seed에서 개별적으로 산출한 OOF 성능의 평균값이며, 본 절의 Recall 82.35%는 5개 Seed OOF Probability를 평균한 Ensemble Risk Score에 Threshold 0.060을 한 번 적용한 정책 Simulation 결과이므로 계산방식이 서로 다름.
- Risk Score만 사용한 경우 전체 17개 불량 중 14건을 포착하였지만 3건의 불량을 미탐함.
- 전체 생산품의 약 1.73%만 검사대상으로 지정할 수 있다는 장점이 있지만, 제조현장에서 실제 불량을 놓치는 FN 비용을 고려하면 보완이 필요했음.

<Risk + Uncertainty 적용>

- Seed별 모델 예측결과가 서로 일치하지 않는 사례를 Uncertainty로 정의하여 추가 검사대상으로 포함함.

지표	Risk Only	Risk + Uncertainty
TP	14	15
FP	7	10
FN	3	2
TN	1,187	1,184
Precision	66.67%	**60.00%**
Recall	82.35%	88.24%
검사대상	21	25
검사율	1.73%	**2.06%**

- Risk + Uncertainty 정책에서는 검사대상이 21건에서 25건으로 4건 증가함.
- 개발 데이터의 OOF Prediction을 이용한 검사정책 Simulation에서 Uncertainty를 추가하자 검사대상은 21건에서 25건으로 4건 증가하였으며, 그중 1건이 추가 불량으로 확인됨. 이에 FN은 3건에서 2건으로 감소하고 Recall은 82.35%에서 88.24%로 상승함.
- 단, 해당 88.24%는 개발 데이터 내부 OOF 기반 정책 Simulation 결과이며 실제 미래 생산구간의 현장 Recall을 의미하지 않음. 실제 Future E4/E5에서는 동일 정책이 불량을 탐지하지 못한 한계가 확인됨.
- 즉 전체 제품 중 추가로 약 0.33%p를 검사함으로써 내부 OOF 기준 미탐 1건을 추가 포착할 수 있었음.
- 이는 불량 미탐비용이 높은 제조현장에서 단순 위험확률뿐 아니라 모델 간 예측 불일치를 검사 우선순위에 활용할 수 있음을 보여줌.

4) Future E4/E5 실패조건

<Future E4 — 2020-10-27>

항목	결과
Future E4 Holdout(제품 행)	628건
실제 불량	10건
PR-AUC	**0.1156**
TP	0
FN	**10**
Recall	**0%**
검사대상	0건

- E4의 불량 10건을 모두 놓쳤고 기존 E1~E3와 다른 신규 Failure Regime

으로 확인됨(E3-E4 상관계수 -0.5566, 거리 28.243).

< Future E5 — 2020-11-03>

항목	결과
Future E5 Holdout(제품 행)	926건
실제 불량	1건
PR-AUC	**0.0147**
TP	0
FN	**1**
Recall	**0%**

※ Future E4/E5의 LightGBM 평가는 제품 행(Side) 단위이며, 아래 PCA-OOD 평가는 동일 TimeStamp의 LH/RH를 하나로 묶은 Cycle 단위임. E4는 628개 제품 행 = 314 Cycle이며, 불량 10개 제품 행 = 5개 불량 Cycle임. E5는 926개 제품 행 = 463 Cycle이며, 불량은 제품 행 및 Cycle 기준 모두 1건임. - E5 역시 해당 불량에 대해 매우 낮은 위험도를 출력함.

- E5는 정상공정과 매우 유사한 불량으로, 실패조건은
  ① 학습하지 않은 신규 Failure Regime
  ② 센서상 정상과 유사한 불량으로 정리됨.
- Ensemble Uncertainty는 모델 간 의견 차이는 포착하지만 모든 모델이 함께 낮은 Risk를 내는 Distribution Shift에는 한계가 있었으며, 이를 보완하기 위해 과거 정상 Cycle만 학습하는 PCA-OOD 안전계층을 추가 검증함.

5) PCA-OOD 안전계층 보완실험

- 제품 행 기준 결과와 구분하여 Cycle-level로 재구성한 E4 기준, 기존 Risk Only와 Risk + Uncertainty는 모두 TP 0, FN 5, Recall 0%였으나 PCA-OOD는 TP 4, FP 0, FN 1로 Precision 100%, Recall 80%, F1 0.8889를 기록함.
- PCA-OOD의 E4 검사대상은 314 Cycle 중 4 Cycle로 검사율은 1.27%였으며, 기존 분류모델이 낮은 Risk를 출력한 신규 Failure Regime을 정상 공정분포 이탈로 별도 포착할 수 있음을 확인함.
- 반면 E5에서는 OOD 6 Cycle이 발생했지만 실제 불량 1 Cycle은 미탐하

여, OOD도 센서상 정상과 중첩되는 Hard Defect까지 해결하지는 못함.

- 따라서 CN7의 실패조건을 ① 기존 패턴과 다른 신규 Failure Regime(OOD로 일부 보완 가능) ② 현재 센서공간에서 정상과 중첩되는 Hard Defect(기존 품질검사 유지 필요)로 구분함.

6) CN7 오류분석 종합

- CN7 모델은 학습된 Failure Regime과 유사한 공정조건에서는 높은 PR-AUC와 Recall을 보임.
- 또한 Risk + Uncertainty 정책을 적용하면 내부 OOF에서 전체 제품의 약 2.06%만 검사하면서 17개 불량 중 15개를 포착할 수 있었음.
- 기존 Risk/Uncertainty는 E4/E5와 같이 학습데이터와 다른 형태의 불량에서 성능이 급격히 저하되었으나, PCA-OOD 안전계층은 E4의 신규 Failure Regime에서 5개 불량 Cycle 중 4개를 포착함.
- PR-AUC 0.8164 ± 0.0181은 미래 Episode 일반화 성능이 아니라 개발 데이터 내부의 Group-OOF 판별성능으로 해석함.
- Future E4에서는 OOD를 통해 Recall 80%의 보완효과를 확인했지만 E5는 여전히 미탐되었으므로 내부 성능, 미래 시간 일반화 성능, OOD 안전계층의 역할을 구분하여 제시함.
- 따라서 최종 CN7 시스템은 기존 Failure Pattern에는 LightGBM Risk/Uncertainty를, 새로운 공정분포 이탈에는 PCA-OOD를 적용하고, 센서상 정상과 중첩되는 Hard Defect에는 기존 품질검사를 유지하는 다중 안전장치형 의사결정 지원시스템으로 정의함.

○ 2. RG3 영향요인 및 오류분석

1) 주요 영향요인 분석

- RG3에서는 Original Feature 기반 LightGBM의 SHAP 분석을 통해 모델이 어떤 공정변수를 중심으로 불량을 구분하는지 확인함.
- 주요 예측 기여변수는 다음과 같음.

순위	주요 변수	Mean |SHAP|
1	Plasticizing_Position	0.5959
2	Max_Switch_Over_Pressure	0.5740
3	Max_Injection_Speed	0.5355

4	Barrel_Temperature_4	0.3996
5	Mold_Temperature_4	0.3521

- 주요 변수는 **가소화 위치, 사출 압력·속도, Barrel/Mold 온도**영역에 분포함.
- 다만 RG3는 생산 Session에 따라 공정 기준점이 달라졌으므로, 해당 변수를 직접적인 불량 원인으로 해석하지 않고 **모델의 위험도 예측에 기여한 변수**로 한정하여 해석함.
- 이러한 문제를 보완하기 위해 최종 모델에서는 센서의 절대값보다 최근 5 Cycle의 기준상태에서 얼마나 벗어났는지를 나타내는 Absolute EWMA5 Feature를 사용함.

2) 모델이 상대적으로 잘 작동한 조건

- RG3 모델은 현재 공정값이 최근 생산상태에서 뚜렷하게 이탈한 불량에 대해서는 상대적으로 높은 Risk Score를 부여함.
- Session 1~2에서 학습하고 미래 Session 3을 평가한 결과 XGBoost + Absolute EWMA5 모델은 다음 성능을 기록함.

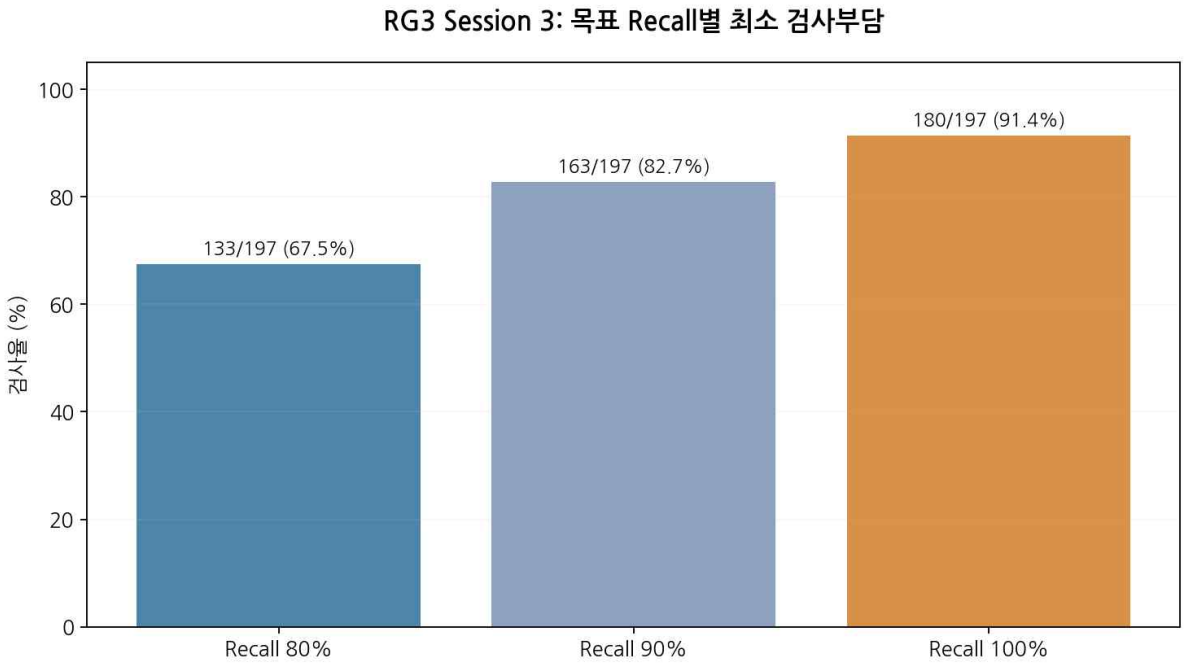
항목	결과
PR-AUC	**0.3136**
ROC-AUC	**0.6642**
Validation 불량률	5.08%
PR Lift	**6.18배**

- 특히 Validation 불량 10건 중 일부는 Risk Rank **2, 3, 4, 5, 15위**에 위치하여 고위험군에 효과적으로 배치됨.
- 따라서 **최근 공정기준에서의 이탈이 명확한 불량**에서는 모델이 검사 우선순위를 제공할 가능성을 확인함.

3) 미탐 및 오경보 분석

- 반면 동일한 불량 10건의 전체 Risk Rank는 다음과 같이 크게 분산됨.
- **2, 3, 4, 6, 23, 60, 109, 133, 163, 180**
- 일부 불량은 상위 Risk 영역에 위치했지만, 일부는 정상제품과 유사한 낮은 Risk Score를 받아 사실상 Hard Defect로 나타남.

- 이 때문에 높은 Recall을 확보하려면 검사대상 수가 크게 증가함.



목표 Recall	검사대상	검사율	FN
80%	133 / 197	**67.5%**	2
90%	163 / 197	**82.7%**	1
100%	180 / 197	**91.4%**	0

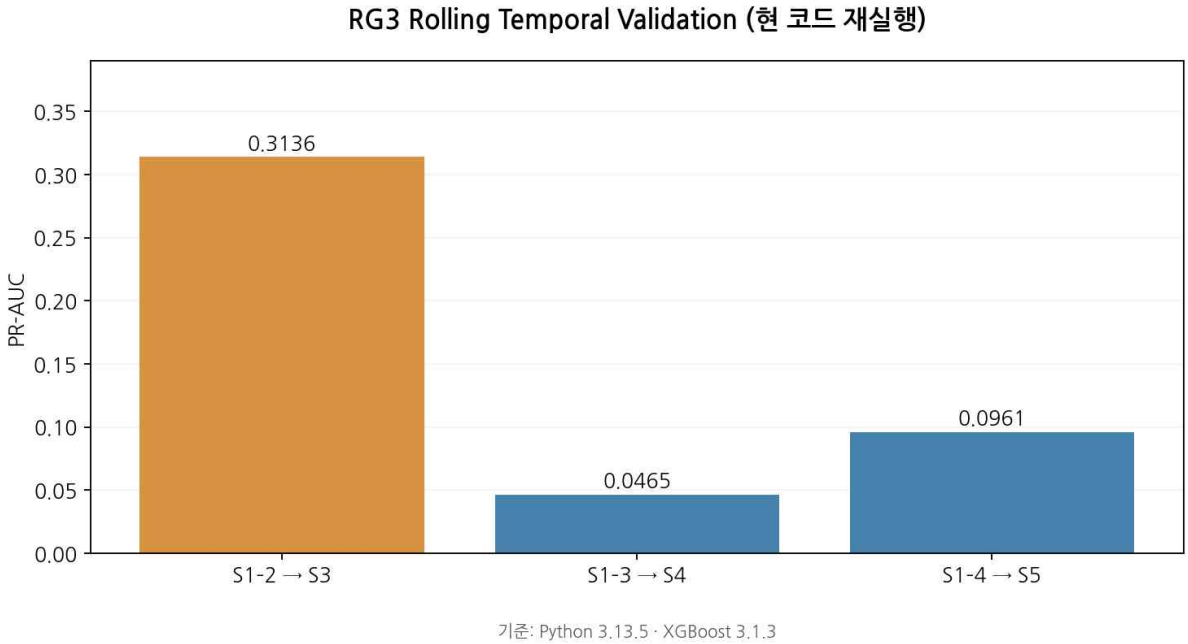
- Recall 100% 달성 자체는 가능했지만 전체 제품의 약 91%를 검사해야 하므로 **검사량 절감이라는 현장 목적을 충족하지 못함.**
- 즉 RG3에서는 미탐을 줄이려 할수록 오경보와 검사대상이 급격히 증가하는 Trade-off가 나타남.

4) Hard Defect 및 미래 Session 실패조건

- 일부 불량은 Risk Rank 163·180위처럼 정상과 유사한 낮은 Risk를 받아 높은 Recall을 확보하려면 검사량이 급증하는 한계가 확인됨. Interaction Feature 보완도 안정적인 개선을 만들지 못해 최종 Feature에는 추가하지 않음.

5) 미래 생산 Session에서의 실패조건

- RG3의 가장 중요한 오류는 **생산 Session이 변경될 때 성능이 안정적으로 유지되지 않았다는 점**임.



검증구간	PR-AUC	PR Lift	ROC-AUC
Session 1~2 → Session 3	**0.3136**	**6.178**	0.6642
Session 1~3 → Session 4	**0.0465**	0.860	0.2964
Session 1~4 → Session 5	**0.0961**	2.819	0.7520

- Session 3에서는 높은 Ranking 성능을 보였으나 Session 4에서는 PR-AUC가 불량률보다 낮아 사실상 유효한 우선순위 효과가 나타나지 않음.
- Session 5에서는 일부 Ranking 능력이 다시 나타났지만 성능 수준은 낮았음.
- 별도로 Session 1~3을 학습하고 Session 4~5를 최종 Holdout으로 평가했을 때도 PR-AUC 0.0415, ROC-AUC 0.4254, PR Lift 1.037으로 나타남.
- 따라서 특정 생산구간에서 학습된 불량패턴이 다음 생산 Session에서도 동일하게 유지된다고 보기 어려움.

실패조건	영향

생산 Session별 기준 공정상태 변화	과거 패턴의 미래 적용성 저하
정상과 유사한 Hard Defect	낮은 Risk Score로 미탐 발생
일부 변수만 선택적으로 변하는 불량	단순 이상크기 기반 탐지 한계
매우 적은 불량 수	모델 및 검증 성능 변동 증가

6) Side 변화와 Target 단위에 대한 추가 오류분석

- 학습구간에서는 불량 25건이 모두 RH였지만 11/04에서는 7건 중 5건이 LH에서 발생하여, Side와 불량의 관계가 미래에도 고정된 규칙이 아님을 확인함.
- 동일 Cycle의 LH/RH가 같은 공정센서값을 공유한다는 점을 고려하면, 제품 Side 단위 예측 실패의 일부는 공정센서 관측단위와 제품 품질 Target 단위의 불일치에서 발생할 가능성이 있음.
- Cycle_Defect 기반 추가 분석에서 PR-AUC 0.4124, PR Lift 2.06이 확인되어 공정센서는 개별 Side의 최종 품질확정보다 해당 Cycle의 상대적 위험순위를 표현하는 데 더 적합할 가능성을 확인함.
- Robust Z 및 Normalized EWMA 후보가 여러 미래 Fold에서 일관된 개선을 만들지 못했으므로, 성능을 높이기 위한 Feature 교체보다 Target 구조와 Session 변화 자체를 오류원인으로 해석함.

7) RG3 오류분석 종합

- RG3에서는 최근 5 Cycle 기준상태에서의 이탈을 나타내는 **Absolute EWMA5**가 Original Feature보다 불량위험을 표현하는 데 상대적으로 유효했음.

- 특히 Session 3에서는 PR-AUC 0.3136로 일부 불량을 상위 Risk 영역에 배치할 수 있었음.

- 그러나 Hard Defect가 정상제품과 유사한 Risk Score를 보였고, 미래 Session별 성능도 크게 변동함.

- 따라서 RG3 모델은 현재 단계에서 **안정적인 자동 불량판정 모델이나 고정된 검사정책으로 적용하기 어렵다**고 판단함.

- 최종적으로 RG3는 **최근 공정상태에서 크게 벗어난 제품을 보조적으로 선별하는 Risk Ranking 모델**로 활용범위를 제한하고, 생산 Session 변

화에 대한 지속적인 성능 모니터링이 필요한 모델로 정의함.

- 추가 Cycle-level 구조진단에서도 11/04 구간에서 PR Lift 2.06의 순위화 신호는 확인되었으나 높은 Recall 확보에는 큰 검사량이 필요했으므로, 기존 결론과 동일하게 자동판정보다 Cycle-level 검사 우선순위 보조로 활용하는 것이 타당함.

□ 제4장. 현장 활용방안〔10점〕

○ 1. CN7

1) 현장 활용 방향

- CN7 최종 모델의 목적은 생산품을 자동으로 정상·불량으로 확정하는 것이 아니라, 생산공정에서 수집되는 센서정보를 이용하여 각 생산품의 불량위험도를 산출하고 품질검사의 우선순위를 결정하는 의사결정 지원도구로 활용하는 것임.
- 최종 LightGBM 모델은 현재 공정센서 23개와 제품 Side 정보, 직전 5 Cycle의 평균 공정상태를 이용하여 각 생산품에 대해 불량위험확률(Risk Score)을 출력함.
- 그러나 오류분석 결과 기존 학습구간과 다른 Failure Regime에서는 모델이 불량을 놓칠 수 있음이 확인되었기 때문에 모델 출력값만으로 제품을 자동 폐기하거나 공정조건을 자동 변경하지 않음.
- 이에 따라 현장 활용체계는 다음 네 가지 정보를 함께 이용하도록 설계함.

모델 출력정보	의미	현장 활용
Risk Score	현재 생산품의 불량위험도	검사 우선순위 결정
Prediction Uncertainty	모델 간 판단 불일치 정도	재검사 및 보수적 검사대상 선정
Feature Contribution	위험판단에 영향을 준 주요 공정변수	공정조건 점검 및 원인분석
Distribution Drift	학습데이터와 현재 공정상태의 차이	신규 공정이상 및 모델 재학습 판단

- 즉 최종 시스템은 예측 → 검사 → 공정점검 → 피드백 → 재학습의 구조로 운영하는 것을 목표로 함

2) Risk + Uncertainty 기반 재검사 기준

- 개발 데이터의 5-Seed OOF Probability를 이용한 검사정책 Simulation에서, Ensemble Risk Score만 적용할 경우 전체 1,211개 제품 중 21건을 검사대상으로 지정하여 실제 불량 17건 중 14건을 포착함.

지표	Risk Only
검사대상	21건
검사율	1.73%
TP	14
FP	7
FN	3
Recall	82.35%
Precision	66.67%

- 하지만 실제 제조현장에서는 오경보로 정상제품을 추가 검사하는 비용보다 실제 불량을 놓치는 미탐 비용이 더 클 수 있음.
- 이에 여러 Seed에서 학습된 모델들의 판단이 서로 다른 생산품을 Uncertainty 제품으로 정의하여 추가 검사대상으로 포함함.
- Risk + Uncertainty 정책의 결과는 다음과 같음.

지표	Risk Only	Risk + Uncertainty
TP	14	15
FP	7	10
FN	3	2
TN	1,187	1,184
Precision	66.67%	60.00%
Recall	82.35%	88.24%
검사대상	21건	25건
검사율	1.73%	2.06%

- 개발 OOF 기반 Simulation에서 추가 검사대상은 4건에 불과했지만 이 가운데 1건이 실제 불량이었으며, Simulation Recall은 82.35%에서 88.24%로 상승함. 단, 이 수치는 실제 미래 생산구간에서 보장되는 성능이 아니라 내부 정책효과를 비교하기 위한 결과임.
- 따라서 현장에서는 다음 기준을 적용할 수 있음.

  Risk Score가 높은 제품 → 1차 우선검사

  Risk Score는 기준 이하이지만 모델 간 예측차이가 큰 제품

  → 재검사 대상
- 이 방식은 단순 Threshold 기반 검사보다 미탐위험을 줄이면서도 전체 생산량 대비 검사대상 증가를 최소화할 수 있다는 장점이 있음.

- PCA-OOD Flag가 발생한 Cycle은 기존 P1~P4와 별도로 P0_OOD로 지정하여 최우선 검사하며, 생산 Session 전체의 분포 이동이 확인되면 모델의 낮은 Risk를 검사면제 근거로 사용하지 않고 기존 품질검사를 유지함.
- 운영은 P1~P4 우선순위로 구분하며 AI가 최종 합격·불합격을 결정하는 것이 아니라 검사순서와 공정점검 수준을 지원함.

등급	조건	현장 조치
P1	Risk가 매우 높거나 위험신호가 반복 발생	즉시 우선검사 및 해당 Cycle 공정조건 확인
P2	Risk ≥ 운영 Threshold	우선 품질검사 실시
P3	Risk는 낮지만 Uncertainty 높음	재검사 또는 추가 샘플링
P4	Risk와 Uncertainty 모두 낮음	기존 일반검사 프로세스 적용

3) 주요 공정점검 및 Drift/OOD 대응

- 고위험 제품은 SHAP 기반 주요 변수와 최근 5 Cycle 추세를 함께 확인하며, Rolling Mean 계열이 전체 예측 기여도의 59.85%를 차지한 점을 반영해 단일 현재값보다 지속적인 공정변화를 우선 점검함.
- E4에서 PCA-OOD가 314 Cycle 중 4 Cycle(1.27%)만 경보하여 5개 불량 Cycle 중 4개를 포착한 결과를 반영해, 낮은 Risk를 곧바로 안전으로 해석하지 않고 학습분포 이탈 Cycle은 별도 OOD 경보 대상으로 우선 검사함.

4) 현장 적용 프로세스

①	생산 Cycle 완료 및 센서정보 수집
	현재 공정센서값과 제품 Side, 직전 5 Cycle의 공정상태를 수집
②	AI Risk Score 산출
	LightGBM 모델이 각 생산품의 불량위험도를 계산
③	Risk / Uncertainty / OOD 평가
	LightGBM 불량위험도와 Seed 간 예측 불확실성을 평가하고, PCA Reconstruction Error 기반 OOD Score로 학습분포 이탈 여부를 함께 감시
④	검사 우선순위 지정
	P1~P4 등급에 따라 우선검사, 재검사 또는 일반검사를 결정

⑤	주요 영향변수 제공
	SHAP 기반으로 해당 Risk에 가장 크게 기여한 공정변수를 검사자에게 제공
⑥	품질검사 및 공정조치
	실제 제품 검사결과와 공정조건을 확인하고 필요한 경우 설비 및 공정조건을 점검
⑦	검사결과 저장 및 모델 피드백
	새로운 불량패턴을 포함한 검사결과를 축적하여 추후 모델 재학습 및 Threshold 조정에 활용

- CN7은 Risk Score + Uncertainty + PCA-OOD + 주요 영향변수를 결합하며, OOD Cycle은 P0 우선검사, 센서상 정상과 중첩되는 Hard Defect는 기존 품질검사를 유지하는 품질검사 우선순위 의사결정 지원시스템으로 활용함.

○ 2. RG3

1) RG3 현장 활용 방향

- RG3 모델의 목적은 제품을 자동으로 정상·불량으로 확정하는 것이 아니라, 생산 Cycle 종료 후 공정센서 정보를 이용하여 RH 제품 및 생산 Cycle의 상대적 위험순위를 제공하는 검사 의사결정 지원으로 정의함.
- 최종 모델은 RH 제품의 23개 공정변수에 대해 최근 5 Cycle의 공정 기준에서 벗어난 정도를 나타내는 **Absolute EWMA5 Feature**를 이용하여 Risk Score를 산출함.
- 다만 Rolling Temporal Validation에서 생산 Session에 따라 성능이 크게 변동하였으므로, 모델 Risk Score만을 이용한 자동 품질판정이나 제품 폐기에는 사용하지 않음.
- 기존 학습데이터에서는 LH 불량사례가 없었으나 이후 11/04에는 LH 불량이 확인되었으므로, Side별 자동판정은 보류하고 LH/RH 모두 기존 품질검사를 유지하며 Cycle-level Risk Ranking을 보조정보로 사용함.

2) Risk Ranking 및 Session 감시

- 모델은 각 RH 생산품에 대해 불량 Risk Score를 산출하고, 위험도가 높은 제품부터 우선적으로 검사하는 방식으로 활용할 수 있음.
- Session 1~2 → Session 3 검증에서는 일부 불량이 Risk Rank **2, 3,**

4, 5, 15위에 위치하여 상위 위험제품 선별 가능성을 확인함.

- 따라서 모델의 활용 목적은 다음과 같이 정의함.

상태	현장 활용
높은 Risk Score	우선 품질검사
중간 Risk Score	추가 Sampling 검사
낮은 Risk Score	기존 검사 프로세스 유지
새로운 생산 Session	모델 신뢰도 확인 후 사용

단, 높은 Recall을 확보하기 위해 Threshold를 지나치게 낮추면 검사 대상이 급격히 증가하므로 고정 Threshold만으로 운영하지 않음.

3) 생산 Session 변화 감시

- RG3에서 가장 중요한 현장 적용조건은 **생산 Session 변화 여부**임.
- Rolling Temporal Validation 결과는 다음과 같음.

검증구간	PR-AUC
Session 1~2 → Session 3	**0.3136**
Session 1~3 → Session 4	**0.0465**
Session 1~4 → Session 5	**0.0961**

- 동일 모델에서도 생산 Session에 따라 성능이 크게 달라짐.
- 따라서 생산중단 후 새로운 Session이 시작되거나 주요 센서의 기준 분포가 크게 변경된 경우에는 기존 모델의 Risk Score를 그대로 신뢰하지 않음.
- 새로운 Session에서는 초기 생산품의 공정분포와 기존 학습분포를 비교하고, 모델성능이 확인되기 전까지 **기존 품질검사를 우선 적용**하도록 함.

- 고위험 제품은 최근 5 Cycle 대비 Absolute EWMA 이탈이 큰 변수를 우선 점검하되, 낮은 Risk 제품도 자동 정상판정하지 않고 기존 검사를 유지함.

4) Cycle-level Risk Ranking 보완

- 이후 생산구간에서 불량 Side가 RH 중심에서 LH 중심으로 이동한 사례

가 확인되어, Side 단위 모델과 별도로 Cycle 단위 위험도 분석을 보조적으로 활용함.

- 11/04 추가 Cycle-level 시간구간에서는 검사 우선순위의 제한적 가능성을 관찰했으나, 제출 ZIP의 Cycle 전용 산출물 기준 상위 20%(7 Cycle) 검사에서 불량 2/7개(Recall 28.57%), 상위 40%(14 Cycle)에서 5/7개(Recall 71.43%)를 포착함. 다만 실행환경에 따라 순위가 달라질 수 있어 참고용 사후 분석으로 한정함.
- 따라서 RG3는 특정 제품을 자동 정상/불량으로 확정하기보다 생산 Cycle 위험순위를 이용해 검사자가 우선 확인할 구간을 제시하고, Side별 기존 품질검사는 유지하는 방식으로 운영함.

5) 현장 적용 프로세스

- RG3의 현장 운영흐름은 다음과 같이 제안함.

① 생산 cycle 완료
→ RH 제품의 23개 공정센서 수집

② 최근 공정상태 계산
→ 동일 Session 내 직전 5 Cycle의 EWMA 기준상태 계산

③ Risk score 산출
→ Absolute EWMA5 Feature를 이용하여 XGBoost Risk Score 생성

④ Session 상태 확인
→ 기존 학습분포와 유사한 생산 Session인지 확인

⑤ 검사 우선순위 결정
→ 높은 Risk 제품 우선검사, 그 외 제품은 기존 검사 유지

⑥ 공정변수 점검
→ 최근 5 Cycle 대비 이탈이 큰 변수 확인

⑦ 실제 검사결과 저장
→ 새로운 불량 및 Hard Defect를 추후 모델 재학습에 활용

6) RG3 현장 활용방안 종합

- RG3 모델은 특정 생산 Session에서는 불량제품을 상위 Risk 영역에 배치하는 효과를 보였으나, 미래 Session별 성능변동이 크게 나타남.
- 따라서 현재 단계에서 **자동 불량판정이나 검사량을 대폭 줄이는 시스템으로 적용하기에는 한계가 있음.**
- 대신 Absolute EWMA5 기반 Risk Score를 이용하여 최근 공정상태에서 크게 벗어난 제품을 우선적으로 확인하는 **보조 Risk Ranking 시스템**으로 활용함.
- 새로운 생산 Session에서는 향후 현장 운영에서는 별도 모니터링으로 공정분포 변화 여부를 확인하고, 성능이 검증되지 않은 경우 기존 품질검사를 유지함.
- 최종적으로 RG3는 **Risk Ranking + 최근 공정이탈 감시 + Session 변화 감시 + 기존 품질검사 유지**를 결합한 보수적인 품질관리 지원체계로 활용하는 것이 적절하다고 판단함.

□ 제5장. 창의성 및 차별성〔10점〕

- 차별성은 새로운 알고리즘 이름보다 데이터 구조 복원, 누수 방지, 시간 검증, 실패조건 공개와 현장 의사결정 연결에 있음. 최고 성능만 선택하지 않고 반증 결과를 최종 결론과 안전장치에 반영함.

○ 1. CN7의 기여

- 생산 Cycle·Side·최근 5 Cycle 공정이력을 함께 표현하는 47개 V5 Feature를 설계하고, 복잡도가 높은 V4보다 운영성·해석성을 고려해 V5를 선택함.
- 모델 확률을 Risk Score로 전환하고 Ensemble Uncertainty를 추가해 개발 OOF 정책 Simulation에서 검사율 2.06%로 Recall 88.24%를 확보함.
- E4/E5 실패를 숨기지 않고 신규 Failure Regime 및 Distribution Shift 문제로 재정의했으며, 과거 정상 Cycle만 학습한 PCA-OOD를 실제 검증하여 E4에서 Precision 100%, Recall 80%, 검사율 1.27%의 안전계층 보완효과를 확인함.

제안 방법	제2·3장 결과	기여
47개 V5 Feature	**내부 반복 Group-CV PR-AUC 0.8164 ± 0.0181**	성능과 복잡도 균형
Risk + Uncertainty	**개발 OOF Simulation Recall 82.35% → 88.24%**	내부 정책 Simulation에서 미탐 감소
PCA-OOD **안전계층 검증**	E4 4/5 Cycle 포착·E5 미탐	신규 Regime 경보와 Hard Defect 한계 구분
SHAP 기반 공정점검	주요 공정변수 식별	검사 이후 공정조치 연결

○ 2. RG3의 기여

- 불량이 RH에만 존재하는 편향을 확인해 RH만 모델링하고 LH 자동판정을 보류함으로써 Shortcut Learning을 방지함.
- 센서 절대값 대신 최근 5 Cycle EWMA 기준에서의 이탈 크기(Absolute EWMA5)를 사용해 반복 CV PR-AUC를 0.1121에서 0.2047로 개선함.
- Random CV 최고점보다 미래 Session 검증을 우선해 XGBoost를 기준 모델로 선택했으며, Holdout 성능저하(0.0415)까지 운영조건과 안전장치 설계에 반영함.

- 11/04에서 불량 Side가 LH 5건・RH 2건으로 변화한 사실을 근거로 공정 센서 관측단위와 Target 단위를 재진단하고, Cycle_Defect 기반 Post-hoc 분석에서 PR-AUC 0.4124, PR Lift 2.06의 제한적 Risk Ranking 신호를 확인함.
- Robust Z 및 Normalized EWMA 후보가 여러 Temporal Fold에서 일관되게 개선되지 않았음을 공개하고 기존 Absolute EWMA5를 유지하여, 단일 최고점보다 반복성과 반증결과를 모델 선택에 반영함.

제안 방법	분석 결과	기여
RH 전용 모델링	불량 25건이 RH에 집중	데이터 편향에 의한 Shortcut 방지
Absolute EWMA5	PR-AUC 0.1121 → 0.2047	최근 공정이탈 표현
Temporal Model Selection	미래 Session에서 XGBoost 0.3136	실제 생산순서를 고려한 모델 선정
Rolling Temporal Validation	Session별 성능변동 확인	Random CV 과대평가 방지
보수적 현장운영	Final Holdout PR-AUC 0.0415	자동판정 대신 Risk Ranking으로 범위 제한

- 모델이 잘 맞는 조건뿐 아니라 언제 신뢰하면 안 되는지까지 명시한 제조 품질 의사결정 지원모델이라는 점이 핵심 차별성임.

□ 제6장. 코드 구성 및 재현성〔10점〕

- 전처리부터 Feature 생성, 분할, 학습, 평가, 추론과 결과저장까지 동일한 실행 흐름으로 재현하도록 구성하고, 함수별 세부 설명은 README에 분리함.

○ 1. CN7 코드 구성 및 재현성

1) 최종 모델 및 재현 설정

항목	최종 설정
모델	LightGBM
원본 공정 Feature	23개
Side Feature	Side_RH1개
Rolling Feature	직전 5 Cycle 평균 23개
최종 Feature	**47개**
Validation	4-Fold StratifiedGroupKFold
Group	TimeStamp
반복 Seed	42, 100, 2026, 777, 1234
불균형 처리	class_weight="balanced"
운영 Threshold	**0.060**
Rolling Window	5 Cycle
Session 기준	생산공백 5분 초과
주요 평가항목	PR-AUC, Precision, Recall, F1, F2

2) 제출 코드 디렉터리 구성

```
CN7/
├── data/
│   ├── raw/
│   │   ├── moldset_labeled_cn7.csv
│   │   ├── labeled_data.csv
│   │   ├── moldset_unlabeled_cn7.csv
│   │   └── unlabeled_data.csv
│   │
│   └── processed/
│       ├── train_cn7_preprocessed.csv
│       ├── cn7_model_input.csv
│       ├── test_cn7_preprocessed.csv
│       └── cn7_test_model_input.csv
│
├── src/
```

```
|   ├── preprocess_cn7.py
|   ├── feature_engineering_cn7.py
|   ├── train_cn7.py
|   ├── evaluate_cn7.py
|   ├── inference_cn7.py
|   ├── config_cn7.py
|   ├── ood_cn7.py
|   ├── temporal_ood_cn7.py
|   └── test_cn7.py
|
├── models/
|   ├── cn7_lgbm_seed42.pkl
|   ├── cn7_lgbm_seed100.pkl
|   ├── cn7_lgbm_seed2026.pkl
|   ├── cn7_lgbm_seed777.pkl
|   ├── cn7_lgbm_seed1234.pkl
|   └── cn7_pca_ood.pkl
|
├── outputs/
|   ├── cn7_oof_prediction.csv
|   ├── cn7_threshold_result.csv
|   ├── cn7_inference_result.csv
|   ├── cn7_metrics.csv
|   ├── cn7_temporal_ood_cycle_results.csv
|   ├── cn7_temporal_ood_side_results.csv
|   ├── cn7_temporal_ood_predictions.csv
|   ├── cn7_test_summary.csv
|   ├── cn7_test_inference_result.csv
|   ├── cn7_test_ood_cycle_result.csv
|   └── cn7_test_flagged_only.csv
|
├── notebooks/
|   ├── cn7_analysis.ipynb
|   └── cn7_ood_safety_layer.ipynb
|
├── requirements.txt
├── requirements.lock.txt
├── run_cn7.py
├── run_cn7_temporal_ood.py
├── run_cn7_test.py
├── README.md
└── OUTPUT_MANIFEST.md
```

- 분석 Notebook은 전체 실험과정을 확인하기 위한 자료로 제공하며, 평가

자의 재실행 편의를 위해 최종 제출코드는 기능별 Python 파일로 분리함

- 실행 흐름: 원본 데이터 → 전처리/생산정보 복원 → 5분 Session → 47개 Feature 생성 → 4-Fold StratifiedGroupKFold × 5 Seeds → LightGBM 학습/OOF 평가 → PCA-OOD 정상분포 학습 → E4/E5 Temporal+OOD 검증 → 신규 데이터 Risk/Uncertainty/OOD 추론.
- Feature 목록・Random Seed・Hyperparameter・Threshold는 config에서 고정하고 requirements.lock.txt에 이번 실행환경의 정확한 의존성 버전을 기록해 재현 절차를 명시하도록 구성함.
- OOD 관련 추가 구성: src/ood_cn7.py(PCA-OOD 학습・추론), src/temporal_ood_cn7.py(E4/E5 시간검증), models/cn7_pca_ood.pkl, run_cn7_temporal_ood.py, run_cn7_test.py, notebooks/cn7_ood_safety_layer.ipynb을 제출 코드에 포함함.
- 재현 시 run_cn7.py → run_cn7_temporal_ood.py → run_cn7_test.py 순으로 실행하며, E4 Cycle-level OOD 결과 Precision 100%, Recall 80%, F1 0.8889, Flag Rate 1.27%가 재현되도록 구성함.
- 별도 unlabeled CN7 35,239건(28,772 Cycle)에 대해 47개 Feature 생성, 5-Seed LightGBM 추론, PCA-OOD 계산, 검사 우선순위 산출 및 CSV 저장까지 전체 inference pipeline이 정상 동작함을 확인함. 정답 Label이 없는 데이터이므로 해당 실행 결과는 성능평가에는 사용하지 않음.

○ 2. RG3 코드 구성 및 재현성

1) 최종 코드 및 파일 구조

```
RG3/
├── data/
│   ├── raw/
│   │   ├── moldset_labeled_rg3.csv
│   │   ├── labeled_data.csv
│   │   ├── moldset_unlabeled_rg3.csv
│   │   └── unlabeled_data.csv
│   │
│   └── processed/
│       ├── train_rg3_preprocessed.csv
│       └── rg3_model_input.csv
│
```

```
├── src/
│   ├── __init__.py
│   ├── config_rg3.py
│   ├── preprocess_rg3.py
│   ├── feature_engineering_rg3.py
│   ├── train_rg3.py
│   ├── evaluate_rg3.py
│   ├── inference_rg3.py
│   └── cycle_analysis_rg3.py
│
├── models/
│   └── rg3_xgb_final.pkl
│
├── outputs/
│   ├── rg3_metrics.csv
│   ├── rg3_oof_prediction.csv
│   ├── rg3_temporal_validation.csv
│   ├── rg3_holdout_prediction.csv
│   ├── rg3_inference_result.csv
│   ├── rg3_risk_prediction.csv
│   ├── rg3_cycle_side_summary.csv
│   ├── rg3_cycle_session_summary.csv
│   ├── rg3_cycle_oot_metrics.csv
│   ├── rg3_cycle_oot_predictions.csv
│   └── rg3_cycle_inspection_tradeoff.csv
│
├── notebooks/
│   ├── rg3_analysis.ipynb
│   └── rg3_cycle_analysis.ipynb
│
├── run_all.py
├── run_rg3.py
├── run_rg3_cycle_analysis.py
├── requirements.txt
├── requirements.lock.txt
├── README.md
└── OUTPUT_MANIFEST.md
```

2) 파일별 역할

파일	역할
preprocess_rg3.py	RH 분리, TimeStamp 변환, 정렬, 상수변수 제거, Session 생성

feature_engineering_rg3.py	Absolute EWMA5 23개 Feature 생성
train_rg3.py	최종 XGBoost 학습 및 모델 저장
evaluate_rg3.py	PR-AUC, ROC-AUC, PR Lift 및 Temporal Validation 수행
inference_rg3.py	신규 생산데이터 Risk Score 산출
config_rg3.py	Feature 목록, Parameter, Session 기준 등 공통 설정
run_rg3.py	전체 분석 Pipeline 순차 실행
rg3_xgb_final.pkl	최종 학습 XGBoost 모델
rg3_risk_prediction.csv	신규 데이터의 위험도 및 검사 우선순위 결과

- 실행 흐름: RH 분리/전처리 → 30분 Session → Absolute EWMA5 23개 생성 → Rolling Temporal Validation → XGBoost 학습 → PR-AUC/ROC-AUC/PR Lift 평가 → 모델 저장 → 신규 데이터 Risk Ranking 생성.
- cycle_analysis_rg3.py: 동일 TimeStamp를 Cycle 단위로 재구성하고 Cycle_Defect, 30분 Session, Absolute EWMA5를 생성한 뒤 2020-11-04 추가 시간구간에서 PR-AUC · ROC-AUC · PR Lift와 검사율별 Recall/Precision을 재현함.
- 모든 공식 출력은 이번 코드의 'python run_all.py'에서 재생성함. 'rg3_metrics.csv'에는 Rolling 3개 Fold, Final Holdout, 사후 Cycle OOT 결과를 함께 저장하며 서로 다른 평가 단위를 구분함.
- RG3 폴더에서 'python run_all.py'를 실행하면 기본 Pipeline 및 Cycle 분석을 순차 실행함. Cycle 분석만 재실행하려면 'python run_rg3_cycle_analysis.py'를 사용함. Cycle 구조진단은 RH 최종모델과 별도 분석임.
  - 이번 실행환경에서 다음 시간 일반화 결과가 재현됨.

검증구간	PR-AUC
Session 1~2 → Session 3	**0.3136**
Session 1~3 → Session 4~5	**0.0415**

- 재현성은 높은 탐색점수뿐 아니라 Session 변화에 따른 Final Holdout 성능저하(0.0415)까지 같은 환경에서 검증하는 것을 목표로 함.
- 전체 재실행 진입점은 'python run_all.py'이며, Rolling 3 Fold의 OOF 예측 447건, Holdout 250건, Cycle OOT 35건과 Test 추론 35,941건을 생성함. 구현되지 않은 자동 Drift Detector는 현장 도입 시 별도 개발할 계획임.

□ 경진대회 만족도 조사 완료 페이지 캡쳐 화면(필수)

- 만족도 조사 url : https://naver.me/FetWt7SN

